

Hadoop Stack

Анатолий Бардуков

ML Engineer в отделе качества поиска, Яндекс

Skillbox

Анатолий Бардуков

10+ лет опыта

в разработке web-сервисов,
из них 4 года работа с большими
данными

100'000'000'000

размер коллекции документов,
с которой приходится работать
каждый день

Backend-/ML-/Data-Engineer —

должности, на которых мне
довелось работать

Создавал

курсы про data engineer-ing,
машинное обучение на больших
данных, сжатие медиаданных, ML-
инжиниринг, писал курсы
для Coursera



Цель модуля

Познакомиться со стеком больших данных Hadoop и парадигмой MapReduce.

Задачи модуля

- 1 Узнать, как устроена файловая система HDFS, и загрузить в неё данные
- 2 Научиться использовать менеджер ресурсов YARN и изучить его параметры
- 3 Изучить парадигму MapReduce для обработки больших данных
- 4 Воспользоваться Hadoop Streaming для обработки данных

История появления Hadoop

Цель видео

Понять, откуда взялся Hadoop и зачем он нужен в современном мире.

Задачи видео


- ✓ Узнать предысторию возникновения парадигмы MapReduce
- ✓ Определить характеристики больших данных
- ✓ Понять, что входит в стек технологий Hadoop
- ✓ Определить, какие компоненты общие для систем работы с большими данными

Большие данные — это вообще что?



«3V of Big Data»

✓ Volume



«3V of Big Data»

✓ Volume

✓ Variety



«3V of Big Data»

✓ Volume

✓ Variety


✓ Velocity

271,330 часов видео в день
загружается на Youtube.

Изображение: [Number of monthly active Facebook* users](#)

* Деятельность компании Meta Platforms Inc., которой принадлежит Facebook, запрещена на территории РФ в части реализации данной социальной сети на основании осуществления ею экстремистской деятельности


Number of monthly active Facebook users worldwide as of 3rd quarter 2022 (in millions)



Sources
Facebook; Meta Platforms
© Statista 2022


Additional Information:
Worldwide; Meta Platforms; Q3 2008 to Q3 2022

Первая встреча с большими данными




Google FS

[Статья 2003 года.](#)



Google MapReduce

[Статья 2004 года.](#)



Зачем нужен MapReduce

	RDBMS	MapReduce
Сервера	Продвинутые	Обычные
Объём данных	Небольшой	Огромный
Время ответа	Моментально	С задержкой
Формат данных	Таблицы (структурированные)	Файлы (без структуры)

Hadoop Stack


Приложение:
MapReduce/Streaming

Приложение:
Spark

Менеджер ресурсов: YARN

Файловое хранилище: HDFS

Hadoop Stack



Выводы видео

- ✓ Изучили историю стека Hadoop как пример реализации вычислительной системы в парадигме MapReduce
- ✓ Посмотрели на влияние Google на технологии работы с большими данными
- ✓ Отметим основные компоненты системы MapReduce и поняли, зачем она нужна