

Архитектура Data Lake


Цель

Узнать про элементы Data Lake:

- каталог
- слои данных
- технологии

Слой сырых данных (Bronze Layer)

Слой сырых данных



Слой сырых данных

- 1 Централизованный репозиторий данных из разных источников
- 2 Данные в оригинальном формате

Слабоструктурированные:



Структурированные:



Слой сырых данных

- 1 Централизованный репозиторий данных из разных источников
- 2 Данные в оригинальном формате
- 3 Данные хранятся в масштабируемом распределённом хранилище



Слой сырых данных

- 1 Централизованный репозиторий данных из разных источников
- 2 Данные в оригинальном формате
- 3 Данные хранятся в масштабируемом распределённом хранилище
- 4 Исторические данные с партицией по дате

08.08.2023

09.08.2023

10.08.2023

11.08.2023

Слой сырых данных


- 1 Централизованный репозиторий данных из разных источников
- 2 Данные в оригинальном формате
- 3 Данные хранятся в масштабируемом распределённом хранилище
- 4 Исторические данные с партицией по дате
- 5 Надёжное хранение с RF = 3+

Технологии



Операционный слой данных

Data Lake



Операционный слой данных


- ❶ Данные провалидированы и структурированы (автоматически или вручную)
- ❷ В новой схеме новые названия и порядок колонок
- ❸ Данные очищены от дубликатов (полных и по ключу)
- ❹ Данные выделены (по вертикали и горизонтали)
- ❺ Данные партиционированы

Технологии



Детальный слой данных (Gold Layer)

Data Lake



Детальный слой данных

Данные:


- агрегированы
- обогащены
- подготовлены для визуализации

Технологии



Каталог данных

Data Lake



Каталог данных

❶ Управление метаданными — информация:

- обо всех источниках
- о качестве данных
- о типах данных
- о трансформации

Каталог данных

- ① Управление метаданными
- ② Data Lineage
 - ссылки на источники данных в слое сырых данных
 - история всех трансформаций
 - возможность пересчёта слоёв Data Lake

Каталог данных

- ❶ Управление метаданными
- ❷ Data Lineage
- ❸ Обнаружение данных (Data Discovery)
 - быстро находить нужные данные среди 200+ интеграций
 - анализировать структуру данных (и не только) в HDFS или Object Storage

Технологии



Итоги

- ❶ Узнали, что такое Data Lake и его реализации
- ❷ Познакомились с преимуществами и недостатками технологий