

Интеграция с внешними источниками



Цели

- ❶ Научиться читать данные из Postgres и писать в CH
- ❷ Научиться читать данные из Object Storage и писать в CH



Data Lake — хранение



?



Data Lake — хранение



Регистрация диалекта

```
from pyspark.sql import SparkSession
from pyspark.sql.jdbc import JdbcDialect, JdbcDialects

class ClickHouseDialect(JdbcDialect):
    def canHandle(self, url):
        return "clickhouse" in url

JdbcDialects.registerDialect(ClickHouseDialect())
```

Spark-сессия и настройка логов

```
spark = SparkSession \
    .builder \
    .appName("JDBC to DF") \
    .config("spark.master", "local[3]") \
    .getOrCreate()

spark.sparkContext.setLogLevel("ERROR")
```

Регистрация диалетка

```
dfFromJDBC = spark \  
  .read \  
  .format("jdbc") \  
  .option("url", "jdbc:postgresql://localhost:5432/postgres") \  
  .option("dbtable", "all_types_table") \  
  .option("user", "docker") \  
  .option("password", "docker") \  
  .load()
```


Чтение из постгреса

```
dfFromJDBC = spark \  
  .read \  
  .format("jdbc") \  
  .option("url", "jdbc:postgresql://localhost:5432/postgres") \  
  .option("dbtable", "source") \  
  .option("user", "docker") \  
  .option("password", "docker") \  
  .load()
```

Чтение из HDFS

```
dfFromHDFS = spark \  
    .read \  
    .format("csv") \  
    .load("user\stage")
```

Конфиг для получателя

```
table = "default.test_target"
batchSize = 10000
parallelism = 3
chUrl = "jdbc:clickhouse://178.154.200.156:9005"
chUser = "default"
chPass = ""
chDriver = "com.github.housepower.jdbc.ClickHouseDriver"
saveMode = "append"
```

Запись

```
dfFromJDBC \  
  .repartition(parallelism) \  
  .write \  
  .format("jdbc") \  
  .mode(saveMode) \  
  .option("driver", chDriver) \  
  .option("url", chUrl) \  
  .option("dbtable", table) \  
  .option("user", chUser) \  
  .option("password", chPass) \  
  .option("createTableOptions", "ENGINE=Log()") \  
  .option("batchsize", batchSize) \  
  .option("isolationLevel", "NONE") \  
  .save()
```

Итоги

- 1 Научились читать данные из Postgres и писать в CH
- 2 Научились читать данные из Object Storage и писать в CH

Итоги модуля

- 1 Выбрали ClickHouse
- 2 Создали таблицы с разными движками
- 3 Оптимизировали запросы
- 4 Загрузили данные из Postge, HDFS, Object Storage