

Типы источников

Чтение и запись с помощью PyArrow

Skillbox

образовательная платформа

Цели видео


- 1 Попрактиковаться в работе с Parquet из Jupyter Notebook
- 2 Поработать с PyArrow

Apache Arrow


Это кросс-платформенное, кросс-языковое, табличное представление данных в памяти с открытым исходным кодом, которое позволяет эффективно передавать данные между ресурсами.



Parquet




Jupyter Notebook




Сравнение результатов

Pandas vs PyArrow | Write time in seconds




Сравнение результатов

Pandas vs PyArrow | Read time in seconds



Финальные размеры файлов



The image shows a macOS Finder window titled 'skillbox_projects'. The left sidebar contains 'Favourites' (AirDrop, Recents, Applications, Desktop, Documents, Downloads), 'iCloud', and 'Tags'. The main pane displays a list of files and folders with columns for Name, Date Modified, Size, and Kind. The files include folders like 'bin', 'etc', 'lib', 'share', and 'temp', as well as CSV files, gzipped archives, a Parquet file, and Jupyter notebooks. The sizes range from 386 bytes to 2.01 GB.

Name	Date Modified	Size	Kind
bin	5 Jul 2022 at 23:14	--	Folder
csv_pandas.csv	Today at 15:40	2.01 GB	Comm...et (.csv)
csv_pandas.csv.gz	Today at 15:45	1.12 GB	gzip co...rchive
csv_pyarrow.csv	Today at 15:51	1.96 GB	Comm...et (.csv)
csv_pyarrow.csv.gz	Today at 15:55	1.13 GB	gzip co...rchive
df.parquet	Today at 15:59	1.27 GB	Document
etc	5 Jul 2022 at 21:00	--	Folder
lib	14 Jun 2022 at 00:02	--	Folder
main.ipynb	Today at 16:01	29 KB	Visual...ocument
pyvenv.cfg	14 Jun 2022 at 00:02	386 bytes	Visual...ocument
share	5 Jul 2022 at 21:00	--	Folder
temp	Today at 15:29	--	Folder

Вывод видео

- 1 Узнали, для чего используется питоновский модуль PyArrow
- 2 Разобрали, как с ним можно работать
- 3 Провели сравнение скорости его работы с модулем Pandas
- 4 Закрепили полученные знания на практике