

Интеграция Airflow и Spark/Hive

В ЭТОМ ВИДЕО

- ✓ Рассмотрите Простые DAG с запуском
- ✓ Рассмотрите Spark
- ✓ Рассмотрите Hive

Интеграция Airflow и Spark/Hive

Запуск Spark Job
с Bash Operator

Запуск Spark Job
с Spark Submit
Operator

Запуск Hive Job
с Hive Operator

Bash Operator

```
spark_command = """
spark-submit \
    --class your.main.Class \
    --master your_spark_master \
    --deploy-mode cluster \
    --executor-memory 4G \
    --num-executors 10 \
    your_spark_application.jar \
    arg1 arg2
"""

# Use BashOperator to execute the spark-
# submit command
run_spark_job = BashOperator(
    task_id='run_spark_job',
    bash_command=spark_command,
    dag=dag,
)
```

Spark Submit Operator

```
dag = DAG(  
    'spark_submit_job',  
    default_args=default_args,  
    description='An Airflow DAG to ',  
    schedule_interval=timedelta(days=1),  
)  
  
spark_job = SparkSubmitOperator(  
    task_id='run_spark_job',  
    application='your_spark_application.jar',  
    name='example-spark-job',  
    conn_id='your_spark_connection',  
    verbose=False,  
    conf={'master': 'your_spark_master'},  
    application_args=['arg1', 'arg2'],  
    dag=dag,  
)
```

Hive Operator

```
dag = DAG(  
    'hive_query_job',  
    default_args=default_args,  
    description='An Airflow DAG to run a Hive query',  
    schedule_interval=timedelta(days=1),  
)
```

```
hive_query = """  
    SELECT * FROM your_table;  
    -- Add more HiveQL queries here as needed  
    """
```

```
run_hive_query = HiveOperator(  
    task_id='run_hive_query',  
    hive_cli_conn_id='your_hive_connection',  
    hql=hive_query,  
    dag=dag,  
)
```

run_hive_query

Выводы по модулю

- ✓ Узнали, что такое Airflow и основные его сущности
- ✓ Рассмотрели написание простых DAG для Airflow
- ✓ Узнали, что такое task, operator, hook, sensor
- ✓ Поняли, как работает планировщик Airflow
- ✓ Узнали, как использовать макросы в задачах
- ✓ Узнали, как передавать данные через XCOM
- ✓ Научились писать задачи с использованием Spark/Hive
- ✓ Научились строить пайплайны в Airflow для наполнения DataLake