

ClickHouse и его особенности


Приглашённый спикер

Сертифицированный консультант в сфере
Big Data и опытом в IT более 15 лет

Skillbox

Приглашённый спикер


✓ Контрибьютор Apache Ignite



✓ Data Engineer



Mercedes-Benz



Обучение и сертификация



Цель модуля

Научиться работать с ClickHouse: создавать различные типы таблиц, наполнять их и создавать аналитические запросы.



Цель модуля

Научиться работать с ClickHouse: создавать различные типы таблиц, наполнять их и создавать аналитические запросы.

Зачем?

Чтобы создать базу для Data Warehouse и Data Marts.



Задачи модуля

- 1 Выбрать ClickHouse
- 2 Создать таблицы с разными движками
- 3 Оптимизировать запросы
- 4 Загрузить данные из Postgres, JDBC

ClickHouse и его особенности


Цели

- 1 Выбрать быстрое хранилище для DWH (ClickHouse)
- 2 Понять ограничение в джойнах в ClickHouse
- 3 Познакомиться с типами данных




Data Lake — источники




Data Lake — слои данных




Data Lake — получатели




Data Lake — оркестрация



Data Lake — хранение



Data Lake — хранение



Проблемы хранилища

- 1 Где хранить большое количество агрегатов слоя DDS?
- 2 Как минимизировать задержку между записью и чтением агрегатов?
- 3 Как оптимизировать место на диске?
- 4 Как ускорить аналитические запросы?
- 5 Как обойтись без джойнов?
- 6 Как загружать данные из внешних источников?

Где хранить большое количество агрегатов слоя DDS?



32 TB



- Ограничен
- Размером дисков Data Node
- Памятью Name Node
- Количеством Data Node



Здесь также нужна
распределённая система

Где хранить большое количество агрегатов слоя DDS?



32 TB



- Ограничен
- Размером дисков Data Node
- Памятью Name Node
- Количеством Data Node



Здесь также нужна
распределённая система

Click House

- ❶ Колоночная MPP база данных
- ❷ Разработана в Яндексе
- ❸ Написана на языке C++
- ❹ Open Source (cloud + onprem)
- ❺ Не тормозит:)




Click House: основные фишки

- 1 Распределённая БД
- 2 Векторная обработка запросов
- 3 Компрессия данных
- 4 Поддержка SQL
- 5 Репликация и шардирование
- 6 Комплексные типы данных
- 7 Поддержка геоданных
- 8 Интеграция с PG, Rabbit, MySQL, Kafka



Распределённая архитектура



Масштабирование

