

Работа с аналитическими БД


Вадим Опольский

Сертифицированный консультант в
сфере Big Data и опытом в IT более 15
лет

Skillbox

Вадим Опольский

- ✓ Контрибьютор Apache Ignite
- ✓ Data Engineer



Mercedes-Benz



POCATOM



Обучение и сертификация



Цель модуля

Научиться работать с аналитическими БД
на примере [Greenplum](#).

Цель модуля

Научиться работать с аналитическими БД
на примере [Greenplum](#).

Зачем?

Чтобы строить DWH/Data Marts

Задачи модуля

- 1 Понять роль MPP OLAP-баз в аналитике и их особенности
- 2 Познакомиться с архитектурой Greenplum
- 3 Научиться строить структуру, партиционировать и сегментировать таблицы
- 4 Познакомиться с внешними таблицами

Роль MPP OLAP-баз в аналитике

Цели

- 1 Узнать назначение MPP OLAP-баз
- 2 Узнать, какие есть аналитические базы

Что такое DWH?



- Построена на основе DB
- Данные загружаются из источников
- Из десятков разных источников
- Данные именно копируются
- И это исторические данные
- Периодически копируются
- Источники всегда структурированы










OLTP — ИСТОЧНИКИ




OLAP — получатели




DWH, HL промежуточные слои




DWH, HL промежуточные слои




Data Lake — оркестрация




Файловые хранилища для слоёв



Хранилища для слоёв?



Хранилища для слоёв?



Какие проблемы в слоях данных?

- Где хранить большое количество данных Golden- или Data Marts-слоёв?
- Как минимизировать задержку между записью и чтением агрегатов?
- Как оптимизировать место на диске?
- Как ускорить аналитические запросы?
- Как джойнить распределённые данные?
- Как загружать данные из внешних источников?

Где хранить большое количество агрегатов слоя DDS?



32 TB



Ограничен размером
дисков Data Node,
памятью Name Node,
количеством Data Node



Здесь также нужна
распределённая
система

Massive Parallel Processing (MPP)



32 TB



Ограничен размером
дисков Data Node,
памятью Name Node,
количеством Data Node,
скоростью

MPP

Здесь также нужна
распределённая
система

MPP


Преимущества:

- Выделенные ресурсы
- Партиционирование и индексы
- Распределение запросов и избыточность данных


Недостатки:

- Проблемы с неравномерным распределением данных и сложными запросами
- Масштабируемость — сложно при необходимости изменения схемы распределения данных


Какие решения?




Какие решения?



Какие решения?



Какие решения?



Greenplum — это

- MPP (Massive Parallel Postgres)
- Поддерживается Аренадата
- Построена на основе PostgreSQL
- Open Source (cloud + onprem)



Greenplum: основные фишки

- Распределённое хранение данных
- Column-хранение сжатием данных
- Оптимизатор запросов ORGA
- Отказоустойчивость Greenplum
- Секционирование данных
- Виртуализация данных PXF



Greenplum

Ещё MPP-системы



Apache Impala



Не рассматриваются, потому что...

- Ограниченная масштабируемость
- Ограниченная поддержка для форматов
- Ограниченная экосистема



Apache Impala

Итоги

- ❶ Узнали назначение MPP OLAP-баз
- ❷ Узнали, какие есть аналитические базы