


Автоматизация ETL-процессов


Цель видео

Научиться автоматизировать загрузку
Hub-, Satellite-, Link-слоёв.

Как это всё объединить в ETL?



Как это всё объединить в ETL?



Шаги создания ETL

1. Создать DAG и встроить скрипт наполнения staging-слоя
2. Создать DAG и встроить скрипты наполнения слоя данных с Hub, Satellite, Link

Создание DAG

```
from datetime import datetime, timedelta
from airflow import DAG
from airflow.models import Param
from datetime import datetime
from airflow.providers.postgres.operators.postgres import PostgresOperator
```

```
default_args = {
    'owner': 'airflow',
    'depends_on_past': False,
    'start_date': datetime(2023, 11, 7),
    'email_on_failure': False,
    'email_on_retry': False,
    'retries': 1,
    'retry_delay': timedelta(minutes=5),
}
```

Создание DAG

```
dag = DAG(  
    'minio-pxf-greenplum-loading',  
    params={  
        "staging_target_schema": Param("staging_s3_target", type="string"),  
        "greenplum_source_schema": Param("pxf_s3_read_source",  
type="string")  
    },  
    default_args=default_args,  
    schedule_interval='@daily',  
    catchup=False  
)
```

Встраивание скрипта наполнения staging-слоя

```
with dag:
    loading_data_sql = """
        INSERT INTO target.h_aircraft (load_date_ts, aircraft_code, model, range)
        SELECT DISTINCT
            CURRENT_TIMESTAMP AS load_date_ts,
            aircraft_code,
            model,
            range
        FROM source.ext_aircrafts_data
        WHERE NOT EXISTS (
            SELECT 1 FROM h_aircraft WHERE h_aircraft.aircraft_code =
            ext_aircrafts_data.aircraft_code);
        ...
    """
```


Встраивание скрипта наполнения staging-слоя

```
green_plum_if_exists = PostgresOperator(  
    task_id='create_greenplum_table',          postgres_conn_id='your_greenplum_connection_id',  
    sql=loading_data_sql,  
    params={'staging_s3_target': 'your_target_table_name',  
            'pxf_s3_read_source': 'your_source_table_name'},  
    dag=dag,  
)
```

```
green_plum_if_exists
```

Создание второго DAG

```
from datetime import datetime, timedelta
from airflow import DAG
from airflow.models import Param
from datetime import datetime
from airflow.providers.postgres.operators.postgres import PostgresOperator

default_args = {
    'owner': 'airflow',
    'depends_on_past': False,
    'start_date': datetime(2023, 11, 7),
    'email_on_failure': False,
    'email_on_retry': False,
    'retries': 1,
    'retry_delay': timedelta(minutes=5),
}
```

Создание второго DAG

```
dag = DAG('hub-loading',  
          params={  
            "hub_target_schema": Param("hub_target", type="string"),  
            "hub_source_schema": Param("hub_source", type="string")  
          },  
          default_args=default_args,  
          schedule_interval='@daily',  
          catchup=False  
)
```

Встраивание скрипта наполнения слоя с Hub

```
with dag:
    loading_data_sql = """
        INSERT INTO h_aircraft (hk_aircraft, aircraft_code, load_date_ts)
        SELECT DISTINCT
            aircraft_code,
            aircraft_code,
            CURRENT_TIMESTAMP
        FROM public.aircrafts_data;
        ...
    """
```

Встраивание скрипта наполнения с Hub

```
green_plum_if_exists = PostgresOperator(  
    task_id='create_greenplum_table',          postgres_conn_id='your_greenplum_connection_id',  
    sql=loading_data_sql,  
    params={'hub_target': 'hub_target_table_name',  
            'hub_source': 'hub_source_table_name'},  
    dag=dag,  
)
```

```
green_plum_if_exists
```


Встраивание скрипта наполнения слоя с Satellite

```
with dag:
    loading_data_sql = """
        INSERT INTO s_aircraft (hk_aircraft, load_date_ts, model, range)
        SELECT
            aircraft_code,
            CURRENT_TIMESTAMP,
            model,
            range
        FROM public.aircrafts_data;

        ...
    """
```

Встраивание скрипта наполнения с Satellite

```
satellite_loading = PostgresOperator(  
    task_id='create_greenplum_table',          postgres_conn_id='your_greenplum_connection_id',  
    sql=loading_data_sql,  
    params={'satellite_target': 'satellite_target_table_name',  
            'satellite_source': 'satellite_source_table_name'},  
    dag=dag,  
)
```

```
satellite_loading
```

Встраивание скрипта наполнения слоя с Link

```
with dag:
    loading_data_sql = """
        INSERT INTO l_aircraft_seat (hk_aircraft, hk_seat, load_date_ts)
        SELECT
            aircraft_code,
            seat_no,
            CURRENT_TIMESTAMP
        FROM public.seats;
        ...
    """
```


Встраивание скрипта наполнения с Link

```
loading_link = PostgresOperator(  
    task_id='create_greenplum_table',          postgres_conn_id='your_greenplum_connection_id',  
    sql=loading_data_sql,  
    params={'link_target': 'link_target_table_name',  
            'link_source': 'link_source_table_name'},  
    dag=dag,  
)
```

```
loading_link
```

Итог видео

Научились автоматизировать загрузку
Hub-, Satellite-, Link-слоёв.

Итоги модуля

Научились разрабатывать ETL
для построения слоёв Data Vault.

Научились организовать периодическую
загрузку данных по методологии
Data Vault.