

Идемпотентность операций в ETL

Цель видео

Научиться писать идемпотентные ETL-процедуры.

Введение в идемпотентность

Идемпотентность — это свойство операций, при котором повторное выполнение операции не изменяет результат. В контексте ETL это означает, что скрипты могут выполняться несколько раз без изменения конечного состояния данных.

Введение в идемпотентность

Идемпотентность — это свойство операций, при котором повторное выполнение операции не изменяет результат. В контексте ETL это означает, что скрипты могут выполняться несколько раз без изменения конечного состояния данных.

Например, в математике идемпотентными операциями являются:


- сложение с нулём
- умножение на единицу
- взятие модуля числа
- выбор максимального значения
- вычисление наибольшего общего делителя
- возведение в степень единицы

Введение в идемпотентность

В контексте Airflow DAG считается идемпотентным, если каждый запуск DAG генерирует одни и те же результаты, даже при многократном запуске. Проектирование идемпотентных DAG сокращает время восстановления после сбоев и предотвращает потерю данных.

Важность идемпотентности в ETL

- **Безопасность данных:** избежание дублирования данных
- **Удобство восстановления:** возможность безопасного повторного выполнения задач после сбоя
- **Консистентность:** обеспечение согласованного состояния данных при многократном выполнении ETL-процессов



Примеры идемпотентных ETL-скриптов

Пример 1: идемпотентный INSERT с использованием **ON CONFLICT**

```
INSERT INTO SalesFact (sale_id, product_id, customer_id, date_id, region_id, amount, quantity)
SELECT sale_id, product_id, customer_id, date_id, region_id, amount, quantity
FROM staging_sales
ON CONFLICT (sale_id) DO NOTHING;
```

Объяснение:

- **INSERT**: вставка данных в таблицу
- **ON CONFLICT**: условие, которое предотвращает дублирование записей при наличии конфликта по ключу

Примеры идемпотентных ETL-скриптов

Пример 2: идемпотентный UPDATE с использованием **MERGE**

MERGE INTO SalesFact **AS** target

USING staging_sales **AS** source

ON target.sale_id = source.sale_id

WHEN MATCHED THEN

UPDATE SET product_id = source.product_id,

customer_id = source.customer_id,

date_id = source.date_id,

region_id = source.region_id,

amount = source.amount,

quantity = source.quantity

WHEN NOT MATCHED THEN

INSERT (sale_id, product_id, customer_id, date_id, region_id, amount, quantity)

VALUES (source.sale_id, source.product_id, source.customer_id, source.date_id, source.region_id, source.amount, source.quantity);

Объяснение:

- **MERGE**: команда объединения данных, которая позволяет обновлять существующие записи и вставлять новые

Итоги модуля

- ✔ Научились моделировать витрины по схеме «звезда»
- ✔ Научились писать SQL-скрипты для наполнения витрин
- ✔ Научились писать идемпотентные ETL-процедуры для наполнения витрин с возможностью перерасчёта