

Контроль качества данных

Вадим Опольский

Сертифицированный консультант в сфере Big Data
с опытом в IT более 15 лет

Skillbox

Цель модуля

Научиться создавать процедуры контроля качества данных и интегрировать их в ETL-пайплайны.

Great Expectations

Зачем?

Чтобы повысить точность вычислений, автоматически мониторить данные и предотвращать проблемы как можно раньше.

Задачи модуля

- 1 Познакомиться с Great Expectations
- 2 Научиться интегрировать Great Expectations с различными источниками данных
- 3 Научиться писать задачи для проверки качества данных в Airflow
- 4 Научиться писать бизнес-правила для данных

Знакомство с Great Expectations

Цели видео

- 1 Узнать, как использовать Great Expectations
- 2 Посмотреть структуру проекта с Great Expectations

Проблемы с мониторингом качества

- ❶ Неправильный тип данных
- ❷ Данные выходят за допустимый диапазон
- ❸ Дублирование данных
- ❹ Пропущенные значения



Great Expectations

- 1 Open source — библиотека для проверки качества данных, документирования, профилирования
- 2 Позволяет автоматически тестировать данные в процессе обработки




Ключевые фичи Great Expectations

- 1 Валидация данных
- 2 Профилирование данных
- 3 Документирование данных



Architecture



Шаги внедрения GE

- 1 Создание проекта и описание требований к данным, например, ограничений, типа и так далее
- 2 Запуск проверки данных на соответствие требованиям
- 3 Создание отчёта с мониторингом данных, включающим, например, визуализацию
- 4 Интеграция проверок данных в пайплайны



Структура проекта GE

```
great_expectations
├── checkpoints
├── expectations
│   └── check_avocado_data.csv
├── great_expectations.yml
├── notebooks
│   ├── pandas
│   │   └── validation_playground.ipynb
│   ├── spark
│   │   └── validation_playground.ipynb
│   └── sql
│       └── validation_playground.ipynb
├── plugins
│   └── custom_data_docs
│       ├── renderers
│       ├── styles
│       │   └── data_docs_custom_styles.css
│       └── views
```



great_expectations.yml

```
datasources:  
  data_dir:  
  batch_kwarg_generators:  
  subdir_reader:  
    class_name: SubdirReaderBatchKwargsGenerator  
    base_directory: ../data  
  module_name: great_expectations.datasource  
  data_asset_type:  
  module_name: great_expectations.dataset  
  class_name: PandasDataset  
  class_name: PandasDatasource
```

great_expectations.yml

Описание: основной конфигурационный файл проекта Great Expectations. Тут настроены датасорсы, генерация документов и другие глобальные настройки.

Ключевые секции:

- **datasources:** конфигурации для источников данных. Например, CSV-файлы, базы данных
- **data_docs_sites:** настройки для генерации сайтов с документами
- **stores:** настройки для хранения артефактов. Например, ожиданий, валидаций

```
datasources:  
  data_dir:  
  batch_kwargs_generators:  
    subdir_reader:  
      class_name: SubdirReaderBatchKwargsGenerator  
      base_directory: ../data  
  
stores:  
  expectations_store:  
  class_name: ExpectationsStore  
  store_backend:  
    class_name: TupleFilesystemStoreBackend  
    base_directory: expectations/  
  
data_docs_sites:  
  local_site:  
  class_name: SiteBuilder  
  show_how_to_buttons: true  
  store_backend:  
    class_name: TupleFilesystemStoreBackend  
    base_directory:  
uncommitted/data_docs/local_site/  
  site_index_builder:  
    class_name: DefaultSiteIndexBuilder
```


checkpoints/

Описание: папка с конфигурациями чекпоинтов.

Файлы:

- **my_checkpoint.yml:** определяет чекпоинт для запуска валидаций. Указывает датасорс, сет ожиданий и другие параметры валидации

expectations/

Описание: папка с наборами ожиданий, которые определяют требования к качеству данных.

Файлы:

- **your_expectation_suite_name.json:** JSON-файл, который хранит ожидания для конкретного сета. Описывает, что ожидается от данных. Например, наличие определённых колонок, отсутствие null-значений

notebooks/

Описание: папка с Jupyter-ноутбуками, используемыми для интерактивного создания и редактирования ожиданий.

Файлы:

- **your_expectation_notebook.ipynb:** Jupyter-ноутбук для интерактивного создания и редактирования ожиданий

plugins/

Описание: папка для кастомных плагинов, расширяющих функционал Great Expectations.

Использование: здесь размещаются кастомные датасорсы, типы ожиданий и другие расширения.

validations/

Описание: папка с валидациями, которые являются результатом проверки данных по ожиданиям.

Файлы:

- **your_validation_results.json:** JSON-файл с результатами валидаций. Включает информацию о том, соответствовали ли данные ожиданиям и какие несоответствия найдены

Итоги видео

- ✓ Узнали, как использовать Great Expectations
- ✓ Посмотрели структуру проекта с Great Expectations