

Подключение Great Expectations к источникам данных

Цели видео

- 1 Узнать, как и к каким источникам можно подключить GE
- 2 Научиться проверять качество данных на файлах

Источники данных

- 1 Реляционные базы данных
- 2 Объектные хранилища данных и MPP (Massive Parallel Processing)
- 3 Файловые системы
- 4 Поточковые источники данных

Реляционные базы данных

```
datasources:  
  oracle_datasource:  
    class_name: SQLAlchemyDatasource  
    module_name: great_expectations.datasource  
    credentials:  
    drivename: oracle+cx_oracle  
    host: <your_oracle_host>  
    port: <your_oracle_port>  
    username: <your_oracle_username>  
    password: <your_oracle_password>  
    database: <your_oracle_service_name>
```

Облачные хранилища данных и MPP

```
datasources:  
  clickhouse_datasource:  
    class_name: SQLAlchemyDatasource  
    module_name: great_expectations.datasource  
    credentials:  
    drivename: clickhouse+http  
    host: <your_clickhouse_host>  
    port: <your_clickhouse_port>  
    username: <your_clickhouse_username>  
    password: <your_clickhouse_password>  
    database: <your_clickhouse_database>
```


Файловые системы

```
datasources:  
  my_csv_datasource:  
    class_name: Datasource  
    module_name: great_expectations.datasource  
    batch_kwargs_generators:  
      subdir_reader:  
        class_name: SubdirReaderBatchKwargsGenerator  
        base_directory: path/to/your/csv_files_directory
```



Источник реального времени — Kafka

```
datasources:  
  spark_datasource:  
    class_name: SparkDFDatasource  
    module_name: great_expectations.datasource  
    spark_config:  
      spark.sql.shuffle.partitions: 8  
      spark.default.parallelism: 8
```

Первая задача на Big Data — проекте

```
taxiDF = spark.read.load("yellow_taxi_jan_25_2018")
taxiZonesDF = spark.read.csv("taxi_zones.csv", header=True, inferSchema=True)

taxiDF.join(taxiZonesDF, col("LocID") == col("LocID")) \
    .groupBy("Borough") \
    .agg(
        count("*").alias("total trips"),
        min("trip_distance").alias("min distance"),
        round(mean("trip_distance"), 2).alias("mean distance"),
        max("trip_distance").alias("max distance")
    ) \
    .write.format("csv") \
    .option("header", "true") \
    .option("sep", "\t") \
    .save("popular_borough.csv")
```


Итоги видео

- 1 Узнали, как и к каким источникам можно подключить GE
- 2 Научились проверять качество данных на файлах