


ETL-процедуры для наполнения staging-слоя (бронзового)

ETL-процедуры для наполнения staging-слоя (бронзового)


Цель видео

Научиться создавать ETL для наполнения staging-слоя (бронзового слоя).

Как это всё объединить в ETL?



Наполнение staging-слоя



Шаги создания ETL с целевыми таблицами

1. Создать и запустить скрипты с целевыми таблицами (разово)
2. Написать скрипт наполнения staging-слоя (включая дедупликацию)

Создание целевых таблиц

```
CREATE TABLE IF NOT EXISTS public.aircrafts_data(  
    aircraft_code VARCHAR(10),  
    model         VARCHAR(50),  
    range         INT,  
    load_date     DATE DEFAULT CURRENT_DATE  
) DISTRIBUTED BY (aircraft_code)  
    PARTITION BY RANGE (load_date)  
    (START ('2024-01-01') END ('2025-01-01') EVERY (INTERVAL '1 day'));
```

Создание целевых таблиц

```
CREATE TABLE IF NOT EXISTS public.seats(  
    seat_no    VARCHAR(5),  
    aircraft_code VARCHAR(10),  
    load_date  DATE DEFAULT CURRENT_DATE  
) DISTRIBUTED BY (aircraft_code)  
    PARTITION BY RANGE (load_date)  
    (START ('2024-01-01') END ('2025-01-01') EVERY (INTERVAL '1 day'));
```

Создание таблиц-источников

```
CREATE EXTERNAL TABLE source.ext_aircrafts_data (  
    aircraft_code VARCHAR(10),  
    model VARCHAR(50),  
    range INT  
)  
LOCATION ('gpfdist://host:port/path/to/aircrafts_data/*.csv')  
FORMAT 'CSV' (DELIMITER ',', NULL '');
```


Создание таблиц-источников

```
CREATE EXTERNAL TABLE source.ext_seats (  
    seat_no VARCHAR(5),  
    aircraft_code VARCHAR(10)  
)  
LOCATION ('gpfdist://host:port/path/to/seats/*.csv')  
FORMAT 'CSV' (DELIMITER ',', NULL '');
```

Подготовка скрипта наполнения staging-слоя

```
INSERT INTO target.h_aircraft (load_date_ts, aircraft_code, model, range)
SELECT DISTINCT
    CURRENT_TIMESTAMP AS load_date_ts,
    aircraft_code,
    model,
    range
FROM source.ext_aircrafts_data
WHERE NOT EXISTS (
    SELECT 1 FROM h_aircraft WHERE h_aircraft.aircraft_code =
ext_aircrafts_data.aircraft_code);
```

Удаление полных дубликатов

```
INSERT INTO target.h_aircraft (load_date_ts, aircraft_code, model, range)
SELECT DISTINCT
    CURRENT_TIMESTAMP AS load_date_ts,
    aircraft_code,
    model,
    range
FROM source.ext_aircrafts_data
WHERE NOT EXISTS (
    SELECT 1 FROM h_aircraft WHERE h_aircraft.aircraft_code =
ext_aircrafts_data.aircraft_code);
```

Запись только новых строк

```
INSERT INTO target.h_aircraft (load_date_ts, aircraft_code, model, range)
SELECT DISTINCT
    CURRENT_TIMESTAMP AS load_date_ts,
    aircraft_code,
    model,
    range
FROM source.ext_aircrafts_data
WHERE NOT EXISTS (
    SELECT 1 FROM h_aircraft WHERE h_aircraft.aircraft_code =
ext_aircrafts_data.aircraft_code);
```

Дедупликация по ключу будет выглядеть таким образом

```
WITH ranked_aircrafts AS (  
    SELECT  
        CURRENT_TIMESTAMP AS load_date_ts,  
        aircraft_code,  
        model,  
        range,  
        ROW_NUMBER() OVER (PARTITION BY aircraft_code ORDER BY CURRENT_TIMESTAMP DESC) AS rnk  
    FROM source.ext_aircrafts_data  
)  
new_aircrafts AS (  
    SELECT  
        load_date_ts,  
        aircraft_code,  
        model,  
        range  
    FROM ranked_aircrafts  
    WHERE rnk = 1)
```


Дедупликация по ключу будет выглядеть таким образом

```
WITH ranked_aircrafts AS (  
    SELECT  
    CURRENT_TIMESTAMP AS load_date_ts,  
    aircraft_code,  
    model,  
    range,  
    ROW_NUMBER() OVER (PARTITION BY aircraft_code ORDER BY CURRENT_TIMESTAMP DESC) AS rnk  
    FROM source.ext_aircrafts_data  
)  
new_aircrafts AS (  
    SELECT  
    load_date_ts,  
    aircraft_code,  
    model,  
    range  
    FROM ranked_aircrafts  
    WHERE rnk = 1)
```

ETL-процедуры для наполнения staging-слоя (бронзового)

Итог видео

Научились создавать ETL-скрипты
для наполнения staging-слоя.