

Hive DML

Цель темы

Разобраться с DML и научиться делать к таблицам простые запросы.

Задачи темы

- ✓ Понять ограничения поддержки DML-операций
- ✓ Разобрать запросы с фильтрацией и сортировкой
- ✓ Разобрать джойны, вложенные запросы, агрегация
- ✓ Hive session parameters

Hive DML

- 1 SELECT: Получение данных
- 2 INSERT INTO: Вставка данных
- 3 UPDATE: Изменение данных в таблице
- 4 DELETE: Удаления из таблицы
- 5 UPSERT: Обновление или вставка
- 6 MERGE: Слияние двух таблиц
- 7 LOAD DATA: Загрузка из файла

SELECT: получение данных

SELECT

column1,
column2,
column3

FROM table_name

[**WHERE** condition]

[**GROUP BY** column_list]

[HAVING condition]

[**ORDER BY** column_list [**ASC|DESC**]]

[**LIMIT** n]

INSERT INTO: вставка данных

Вставка с перезаписью:

```
INSERT INTO table_name [PARTITION (part_column = part_value)]  
VALUES (value1, value2, ...)
```

Вставка с перезаписью:

```
INSERT OVERWRITE table_name [PARTITION (part_column = part_value)]  
VALUES (value1, value2, ...)
```

Вставка сложных типов:

```
INSERT INTO table_name  
SELECT  
    value1,  
    value2,  
    ...;
```

CREATE WITH SELECT

Вставка с перезаписью:

```
CREATE TABLE new_table_name (  
    column1 varchar,  
    column2 int) AS  
SELECT  
    column1,  
    column2  
FROM old_table_name
```


UPDATE: изменение данных в таблице

```
UPDATE table_name  
SET column1 = value1, column2 = value2, ...  
[WHERE condition]
```

```
UPDATE marketplace_clients  
SET client_id = '1003'  
WHERE client_id = '1001';
```


UPDATE, DELETE, MERGE, UPSERT. Ограничения

```
UPDATE marketplace_clients  
SET client_id = '1003'  
WHERE client_id = '1001';
```



FAILED: SemanticException [Error 10294]: Attempt **to** do **update or delete using** transaction manager that does **not** support these operations.

UPDATE, DELETE, MERGE, UPSERT. Решение № 1

```
INSERT OVERWRITE TABLE marketplace_clients  
SELECT '1003', ...  
FROM marketplace_clients  
WHERE client_id = '1001';
```

UPDATE, DELETE, MERGE, UPSERT.

Решение № 2

```
CREATE TABLE marketplace_clients_updated
AS
SELECT CASE
    WHEN client_id = '1001'
    THEN '1003'
ELSE client_id END AS client_id,
...
FROM marketplace_clients;
```

```
ALTER TABLE marketplace_clients
RENAME TO marketplace_clients_old;
ALTER TABLE marketplace_clients_updated
RENAME TO marketplace_clients;
```

LOAD DATA — загрузка данных

```
LOAD DATA [LOCAL] INPATH 'file_path'  
[OVERWRITE] INTO TABLE table_name  
[PARTITION (partition_column = partition_value)]
```

Hive session parameters

```
$ hive --hiveconf mapreduce.job.queueName=PROD
```


Hive parameters

hive.cli.print.header: Определяет, нужно ли выводить имена столбцов в качестве первой строки в результатах запроса. **"true"** или **"false"**.

hive.cli.print.current.db: Определяет, нужно ли отображать текущее имя базы данных в приглашении командной строки Hive. **"true"** или **"false"**.

hive.execution.engine: Определяет исполнительский движок для запросов Hive. **"tez"**, **"mr"** (MapReduce) или **"spark"**.

hive.optimize.bucketmapjoin: Включает или отключает оптимизацию объединения по схеме **"bucket map join"**. **"true"** или **"false"**.

hive.optimize.skewjoin: Включает или отключает оптимизацию скошенного объединения. **"true"** или **"false"**.

Выводы темы

- ✓ Hive поддерживает DML с ограничениями
- ✓ Не используйте операции
- ✓ UPDATE, DELETE, MERGE, UPSERT
- ✓ Некоторые параметры сессии можно использовать
- ✓ Запускать только перед стартом