

MapReduce

Цель видео

Познакомиться с моделью распределённых вычислений MapReduce.

Задачи видео

- ✓ Узнать про задачу Word Count и её решение
- ✓ Познакомиться с подходом MapReduce
- ✓ Разобрать реализацию MapReduce в Hadoop

Задача Word Count (Google)

У вас есть большой текстовый файл
(весь интернет).


Вы хотите узнать количество повторений
каждого слова (например, для TF-IDF).

Решение:

- для каждого блока вычисляйте частоту слов в нём (хорошо масштабируется)
- агрегируйте частоты со всех блоков


Word Count проблема (Google)

Наивный подход




Word Count проблема (Google)

Разделение шага агрегации



Word Count проблема (Google)

Независимая обработка частей



MapReduce

Допустим, вы хотите разделить работу по агрегации на N задач.

Вы разделите работу на **хеш (слово) % N** , что даст номер узла, куда вам нужно отправить это слово.

Из хорошей хеш-функции получаются числовые значения, которые равномерно распределены.


Пример хеш-функции (многочлен):

$$\textit{hash}(s) = s[1]p^1 + \dots + s[n]p^n$$

- s — строка
- p — фиксированное простое число
- $s[i]$ — код символа


MapReduce

Word Count проблема



MapReduce

Word Count проблема



MapReduce

Парадигма MapReduce


Map: (K1, 3n1) List(K2, 3n2)
(номер строки, “кошка спит”) [(“кошка”, 1), (“спит”, 1)]

Shuffle: Ключи делятся по хешу (ключу) % N на N разделов
Каждый раздел **сортируется по ключу** (независимо)

Reduce: (K2, List(3n2)) List(K3, 3n3)
(“кошка”, (1, 1, 1)) [(“кошка”, 3)]


Hadoop MapReduce

- Результаты Map могут быть отсортированы локально
- Затем можно объединить отсортированные результаты Map в один отсортированный результат за линейное время (сортировка слиянием)




Hadoop MapReduce

- Результаты Map могут быть отсортированы локально
- Затем можно объединить отсортированные результаты Map в один отсортированный результат за линейное время (сортировка слиянием)



Hadoop MapReduce

Работа с HDFS



Отказоустойчивость MapReduce

- ✓ При потере маппера необходимо перезапустить задание только для его блоков
- ✓ Если вы потеряли редьюсер, повторно собирайте данные со всех мапперов для хеш-значения редьюсера

Выводы видео

- ✓ Познакомились с задачей Word Count, разобрали решение и улучшили его
- ✓ Узнали про парадигму MapReduce
- ✓ Узнали про реализацию MapReduce в Hadoop