

Spark DataFrame

Антон Коротков

Data Engineer в отделе AntiFrod, Wildberries

Skillbox

Антон Коротков

Data Engineer в отделе AntiFrod, Wildberries,
в ИТ 8 лет, из них 4 года работает
с большими данными.

Цели модуля

- ✓ Научиться использовать DataFrame для чтения и анализа данных
- ✓ Узнать возможности API Spark
- ✓ Научиться писать UDF-функции
- ✓ Научиться использовать инструменты оптимизации запросов
- ✓ Изучить контроль приложения и ресурсов через Spark UI

Немного теории

RDD (resilient distributed dataset) — отказоустойчивый распределённый набор данных, которые используют как основу все наборы/коллекции данных в Spark.

DataFrame (Dataset organized into named columns) — это распределённая коллекция данных, организованных в именованные столбцы, имеет более удобный интерфейс и инструменты для разработки, работает быстрее, чем RDD в python, но в остальных языках скорость не является преимуществом.

Плюсы и минусы DataFrame

Плюсы

- [Catalyst](#) — используется для создания оптимизированного логического и физического плана запроса
- SQL — возможность использовать SQL-запросы при обработке данных
- Ленивые вычисления ускоряют в основном разработку (вычисления нужно производить в любом случае, но тут в ход идёт Catalyst)
- Интуитивно понятный API

Минусы

- Не позволит выявить ошибку до компиляции

Далее перейдём к практике

[read](#) — функция используется для чтения данных, файлов, баз данных, потоков.

[createDataFrame](#) — используется для создания DataFrame.