

Spark — обработка данных

Антон Коротков

Data Engineer в отделе AntiFrod, Wildberries

Skillbox

Антон Коротков

Data Engineer в отделе AntiFrod, Wildberries,
в ИТ 8 лет, из них 4 года работает
с большими данными.

Цели видео

- ✓ Изучить команды работы с данными
- ✓ Работа с партиционированием

Описание основных команд, которые вам точно пригодятся

[sql.function.*](#) — библиотека со всем функциями, которые нужно использовать в работе, если нужно писать UDF, начинайте тут.

[dropna](#) — функция, которая удаляет нули.

[fillna](#) — функция, которая заменяет пустые значения на указанные.

[distinct](#) — возвращает DataFrame уникальными значениями.

[groupBy](#) — группирует по указанному значению.

[join](#) — объединяет DataFrame.

[withColumn](#) — добавляет колонку в DataFrame.

Партиционирование

Партиционирование — это разбиение таблиц на равные части, используется для оптимизации работы с данными.

[coalesce](#) используется для уменьшения партиций, можно и увеличить, но оптимизировано под уменьшение.

[repartition](#) используется для изменения количества партиций.