

Архитектура Spark


Цель видео

Узнать подробнее про устройство Spark.


Задачи видео

- ✓ Узнаете больше про устройство Spark
- ✓ Поймёте, в чём различия между внутренними операциями
- ✓ Увидите, как Spark взаимодействует с YARN

Apache Spark. Компоненты



Apache Spark. Вычисления



Apache Spark. Вычисления


RDD — Resilient Distributed Dataset.

Если разобрать название по частям, то авторы обещают нам:

- набор данных (Dataset)
- который должен быть к чему-то устойчив (Resilient)
- и распределён (Distributed)

В Apache Spark над датасетами можно выполнить 2 типа операций:

- **преобразования (transformations)** — отложенные или ленивые вычисления. Примеры: `map()`, `sample()`



Apache Spark. Вычисления

RDD — Resilient Distributed Dataset.


Если разобрать название по частям, то авторы обещают нам:

- набор данных (Dataset)
- который должен быть к чему-то устойчив (Resilient)
- и распределён (Distributed)

В Apache Spark над датасетами можно выполнить 2 типа операций:

- **преобразования (transformations)** — отложенные или ленивые вычисления. Примеры: `map()`, `sample()`
- **действия (actions)** — функции, запрашивающие вывод. Примеры: `count()`, `first()`

Изображение: [Apache Spark](#)




Apache Spark и YARN

При создании в Python **SparkContext** запускается YARN-приложение.

В Application Master запускается **Driver**, который создаёт JVM-версию SparkContext (хранит конфигурацию, DAG для всех RDD).


Driver координирует работу **Executors** (вычисляют RDD).



Apache Spark и YARN

Spark работает с Python-объектами в сериализованном виде (pickle), они будут десериализованы для обработки в Python. Поэтому элементы RDD занимают память дважды:

- в сериализованном виде в JVM (например, кеш в RAM)
- десериализованный объект в Python



Выводы видео

- ✓ Узнали, что такое Driver, Executor, Stage, Task
- ✓ Посмотрели, чем отличаются actions и transformations
- ✓ Поняли, как Spark взаимодействует с YARN