

Загрузка качественных данных

Байжанов Нурсултан

Senior Data Engineer с опытом в IT более 7 лет

Skillbox

Загрузка качественных данных

Цель модуля

Научиться искать проблемы в данных и исправлять их.

Задачи модуля

- 1 Научиться распознавать и понимать потенциальные проблемы в данных
- 2 Освоить работу с библиотекой Pandas для анализа данных
- 3 Научиться разрабатывать и внедрять ETL-процедуры в Apache Airflow
- 4 Научиться выявлять аномалии в данных
- 5 Овладеть навыками написания тестов для приложений на PySpark

Проблема качества данных

Цель видео

Понять потенциальные проблемы, которые могут возникать в данных, и их последствия.

Определение проблемы качества данных

Качество данных имеет решающее значение для анализа и принятия решений.

Основные проблемы качества данных:

- **Пропущенные значения:** отсутствующие данные, которые могут исказить результаты анализа

Определение проблемы качества данных

Качество данных имеет решающее значение для анализа и принятия решений.

Основные проблемы качества данных:

- **Пропущенные значения:** отсутствующие данные, которые могут исказить результаты анализа
- **Дубликаты:** повторяющиеся записи, которые могут удвоить вес данных и привести к неверным выводам

Определение проблемы качества данных

Качество данных имеет решающее значение для анализа и принятия решений.

Основные проблемы качества данных:

- **Пропущенные значения:** отсутствующие данные, которые могут исказить результаты анализа
- **Дубликаты:** повторяющиеся записи, которые могут удвоить вес данных и привести к неверным выводам
- **Неправильные данные:** данные, которые не соответствуют ожидаемым значениям или форматам

Определение проблемы качества данных

Качество данных имеет решающее значение для анализа и принятия решений.

Основные проблемы качества данных:

- **Пропущенные значения:** отсутствующие данные, которые могут исказить результаты анализа
- **Дубликаты:** повторяющиеся записи, которые могут удвоить вес данных и привести к неверным выводам
- **Неправильные данные:** данные, которые не соответствуют ожидаемым значениям или форматам
- **Несогласованные данные:** различия в форматах данных или кодировках, которые затрудняют их интеграцию

Последствия плохого качества данных

- Неправильные решения на основе неверных данных
- Увеличение затрат на исправление ошибок
- Потеря доверия к данным и системе в целом
- Снижение продуктивности
- Разочарование клиентов и потеря прибылей



Пример: пропущенные значения

```
import pandas as pd
data = {'name': ['Alice', 'Bob', 'Charlie', None, 'Edward'],
        'age': [25, 30, 35, None, 40],
        'income': [50000, 54000, None, 62000, 58000]}
df = pd.DataFrame(data)
print(df)
```

Вывод:

name	age	income
Alice	25	50000
Bob	30	54000
Charlie	35	NaN
None	NaN	62000

Пример: пропущенные значения

```
print("Пропущенные значения в каждой колонке:\n", df.isnull().sum())
```

Пропущенные значения
в каждой колонке:

name	1
age	1
income	1

```
1 import pandas as pd
2 data = {'name': ['Alice', 'Bob', 'Charlie', None, 'Edward'],
3         'age': [25, 30, 35, None, 40],
4         'income': [50000, 54000, None, 62000, 58000]}
5 df = pd.DataFrame(data)
6 print("Пропущенные значения в каждой колонке:\n", df.isnull().sum())
```

main ×

Пропущенные значения в каждой колонке:

name	1
age	1
income	1

dtype: int64

Пример: пропущенные значения

```
df = df._append(df.iloc[0], ignore_index=True)
print("Количество дубликатов:", df.duplicated().sum())
```

Количество дубликатов: 1

```
1 import pandas as pd
2 data = {'name': ['Alice', 'Bob', 'Charlie', None, 'Edward'],
3         'age': [25, 30, 35, None, 40],
4         'income': [50000, 54000, None, 62000, 58000]}
5 df = pd.DataFrame(data)
6 #print("Пропущенные значения в каждой колонке:\n", df.isnull().sum())
7 df = df._append(df.iloc[0], ignore_index=True)
8 print("Количество дубликатов:", df.duplicated().sum())
```

Количество дубликатов: 1