

Hive

Skillbox

Цель модуля

Научиться работать с данными на распределённых хранилищах.

Зачем?

Предоставлять SQL-доступ к результатам загрузки и обработки данных.

Задачи модуля

- 1 Познакомиться с Hive
- 2 Разобраться с архитектурой Hive
- 3 Научиться накрывать данные DDL
- 4 Написать простые DML

Hive

Skillbox

Инструмент Hive

Цели

- 1 Разобраться, что такое SQL-движок
- 2 Сравнить Hive с аналогами Presto, Impala, Trino

Повторим некоторые понятия

Повторение — мать учения

❶ Объектное хранилище

❷ HDFS

❸ Форматы данных

❹ SQL

❺ Spark

Повторение — мать учения

❶ Объектное хранилище

❷ HDFS

❸ Форматы данных

❹ SQL

❺ Spark

Объектное хранилище



Yandex Object Storage



Повторение — мать учения

❶ Объектное хранилище

❷ HDFS

❸ Форматы данных

❹ SQL

❺ Spark

HDFS

The Cloudera logo, featuring the word "CLOUDERA" in a bold, orange, sans-serif font.The Yandex Cloud Data Proc logo, featuring the word "Yandex" in a bold, black, sans-serif font, followed by a blue circular icon with a white dot, then the word "Cloud" in a bold, black, sans-serif font, and "Data Proc" in a bold, black, sans-serif font below it.

Повторение — мать учения

❶ Объектное хранилище

❷ HDFS

❸ Форматы данных

❹ SQL

❺ Spark

Форматы данных

1 Структурированные



2 Полуструктурированные



3 Неструктурированные



Повторение — мать учения

❶ Объектное хранилище

❷ HDFS

❸ Форматы данных

❹ SQL

❺ Spark


```
SELECT
  OrderH.invoiceNo, OrderH.invoiceDate, OrderH.customerCode,
  OrderD.itemCode, I.itemName, OrderD.qty, OrderD.netPrice
FROM
  OrderHeader AS OrderH
  INNER JOIN Customer AS Cust ON OrderH.customerCode = Cust.customerCode
  INNER JOIN OrderDetail AS OrderD ON OrderH.orderId = OrderD.orderId
  INNER JOIN Item AS I ON OrderD.itemCode = I.itemCode
WHERE
  OrderD.netPrice > 1000
ORDER BY
  OrderH.customerCode, OrderD.netPrice
```

Повторение — мать учения

❶ Объектное хранилище


❷ HDFS

❸ Форматы данных

❹ SQL

❺ Spark

Apache Spark




Зачем нужен Apache HIVE?



Есть HDFS или хранилище объектов



С данными



Аналитики, QA и бизнес





Вопрос 1

Как аналитикам, QA и бизнесу
прочитать эти данные?

С учётом того, что они знают только SQL.

Аналитики, QA и бизнес



SQL-движок — HIVE



Apache HIVE — это...

- 1 SQL-движок с доступом к данным в различных форматах
- 2 SQL-доступ к данным на HDFS и различных объектных хранилищах
- 3 Абстракция SQL для интеграции HiveQL-запросов в Java MapReduce
- 4 HiveQL — анализ, суммирование данных, оконные функции
- 5 HiveQL не предназначен для обработки онлайн-транзакций (OLTP)
- 6 HiveQL разработан для обработки онлайн-аналитических задач (OLAP)
- 7 HiveQL разработан для пакетной обработки больших наборов данных

Изображение: [HIVE](#)



Есть же ещё SQL-движки



Не рассматриваются, потому что...

- ❶ Ограниченная поддержка сложных запросов
- ❷ Высокое использование памяти
- ❸ Ограниченная экосистема



Не рассматриваются, потому что...

- ❶ Ограниченная масштабируемость
- ❷ Ограниченная поддержка для форматов
- ❸ Ограниченная экосистема




Не рассматриваются, потому что...

- ❶ Высокий порог входа
- ❷ Ограниченная поддержка для форматов
- ❸ Низкая производительность с большими наборами данных





Зачем ещё нужен Apache HIVE?

Процессинг данных



DWH- и DB-разработчики





Вопрос 2

Как DB- или DWH-разработчикам
процессить эти данные?

С учётом того, что они знают только SQL.

DWH- и DB-разработчики



SQL-движок — HIVE



Apache HIVE — это...

- 1 Масштабируемость
- 2 Оптимизация запросов
- 3 Data partitioning and bucketing
- 4 Интеграция с экосистемой Hadoop
- 5 Schema evolution
- 6 Контроль обработки с красивым UI



HIVE — это только SQL-движок, не хранилище или БД

Ещё нужны:

- хранилище с файлами
- Metastore
- ресурсный менеджер
- оркестратор
- Execution engine

Изображение: [HIVE](#)



Итоги

- ❶ SQL-движок — удобное API для работы с данными
- ❷ Hive, по сравнению с аналогами Presto, Impala, Trino, — наиболее устойчивый и не ресурсоёмкий