

Spark — RDD

Антон Коротков

Data Engineer в отделе AntiFrod, Wildberries

Skillbox

Антон Коротков

Data Engineer

в отделе AntiFrod, Wildberries

8 лет в IT

из них 4 года работает с большими данными

Цель модуля

Научиться использовать Spark для задач обработки данных.

Задачи модуля

- ✓ Узнаете про назначение Spark и познакомитесь с его архитектурой
- ✓ Познакомитесь с RDD в Spark
- ✓ Запустите Spark-приложение

Назначение Spark

Цели видео

- ✓ Познакомиться с фреймворком Spark
- ✓ Научиться использовать его для обработки данных

Задачи видео

- ✓ Узнаете, для чего можно использовать Spark
- ✓ Познакомитесь с надстройками над Spark

Apache Spark

Spark (полное название Apache Spark) — мультязычный инструмент для инженерии данных, data science и машинного обучения на отдельных узлах или в кластерах.

Хранит и обрабатывает данные в оперативной памяти вместо файловой системы.




Apache Spark

Основные преимущества

- Открытый исходный код
- API для Java, Scala, Python (Pyspark), R
- Стоимость
- Экосистема, библиотеки
- Удобство
- Работа с источниками
- Интерактивный режим



Spark-экосистема



Spark-настройки

Spark SQL — для выполнения операций с данными либо с использованием API и большим количеством встроенных функций, либо на языке SQL.

Назначение Spark

Spark-надстройки

MLlib — для машинного обучения.


Spark-настройки

Spark Streaming — для потоковой и пакетной обработки данных.



Spark-надстройки

GraphX — для использования графовых структур данных.



Выводы видео

- ✓ Узнали, для чего можно использовать Spark
- ✓ Познакомились с надстройками над Spark (Streaming, SQL, ML, GraphX)