

Управление ETL-процессами с помощью Apache Airflow

Цель модуля

Научиться использовать Airflow для создания и оркестрации ETL-пайплайнов.

В результате модуля ВЫ...

- ✓ Узнаете, что такое Airflow и основные его сущности
- ✓ Научитесь писать простые DAG для Airflow
- ✓ Узнаете, что такое task, operator, hook, sensor
- ✓ Поймёте, как работает планировщик Airflow
- ✓ Поймёте, как использовать макросы в задачах
- ✓ Узнаете, как передавать данные через XCOM
- ✓ Научитесь писать задачи с использованием Spark/Hive
- ✓ Научитесь строить пайплайны в Airflow для наполнения DataLake

Назначение оркестраторов

В ЭТОМ ВИДЕО

- ✓ Узнаете, что такое оркестраторы
- ✓ Поймёте, какие задачи они решают
- ✓ Узнаете, какие решения применяются на практике

Что такое оркестраторы

Оркестратор — инструмент, управляющий периодическими задачами.

Он не выполняет тяжёлую работу по перекладке и обработке данных, он говорит другим системам и фреймворкам, что надо делать, и следит за статусом выполнения.

Какие задачи решают оркестраторы?

- Планирование задач
- Управление зависимостями
- Репроцессинг
- Мониторинг
- Управление ресурсами

Какие решения применяются на практике?

- Apache Oozie
- Luigi
- Apache NiFi
- Dagster
- DataStage
- Talend
- SAS



Назначение оркестраторов

Talend Open Studio

TOS — это open-source-решение для интеграции данных. Основным средством настройки процесса преобразования данных в TOS является специальный визуальный редактор, позволяющий добавлять и настраивать отдельные узлы преобразования данных и связи между ними.

Talend Open Studio

Преимущества:

- простота создания ETL-пайплайнов
- масштабируемость
- трансформация блоков в код Java
- интеграция с Hadoop, Spark (BigData)

Недостатки:

- знание Java для расширения функционала
- не весь функционал задокументирован
- непростая отладка при падении джобов

IBM DataStage

IBM DataStage — это технология, используемая для агрегирования данных из многих источников перед их передачей в бизнес-приложения или хранилища данных. Включены как интерфейс проектирования, так и механизм выполнения.

IBM DataStage

Преимущества:

- простота создания ETL-пайплайнов
- масштабируемость
- невысокая стоимость
- интеграция с Hadoop, Hive (BigData)

Недостатки:

- функционал ограничен блоками конструктора
- не весь функционал задокументирован
- непростая отладка при падении джобов

Luigi

Luigi — фреймворк на языке Python для построения сложных последовательностей по выполнению зависимых задач. Фреймворк разрешает зависимости, формирует граф выполнения, управляет запуском задач, обрабатывает ошибки с возможностью перезапуска нужных задач, распределяет ресурсы рабочих процессов с возможностью параллельной работы независимых частей графа задач.

Luigi

Преимущества:

- код на Python
- удобная отладка при сбоях
- Open Source
- интеграция с Hadoop, Hive, Spark (BigData)

Недостатки:

- нет полноценного планировщика (cron)
- плохо масштабируемый
- малофункциональный пользовательский интерфейс

Oozie

Oozie — это система для планирования выполнения повторяющихся задач в экосистеме Hadoop. В этой системе можно сконфигурировать цикл задач, написанных на Java, Apache Hive, Apache Pig и Apache Sqoop, Apache Spark, UNIX Shell и т. д.

Oozie

Преимущества:

- тесная интеграция с экосистемой Hadoop
- масштабируемость
- Open Source
- интерфейс с конструктором джобов

Недостатки:

- для запуска задач нужно писать XML-файл
- желательно знание Java
- не самый удобный веб-интерфейс

Oozie

```
<workflow-app name="example-oozie-workflow">
  <start to="hive-node"/>

  <action name="hive-node">
    <hive xmlns="uri:oozie:hive-action:0.5">
      <job-tracker>${jobTracker}</job-tracker>
      <name-node>${nameNode}</name-node>
      <script>/user/example/hive-script.hql</script>
      <!-- Add configuration properties as needed -->
    </hive>
    <ok to="sqoop-node"/>
    <error to="fail"/>
  </action>

  <kill name="fail">
    <message>Workflow failed, error
    message[${wf:errorMessage(wf:lastErrorNode())}]</message>
  </kill>

  <end name="end"/>
</workflow-app>
```

Dagster

Dagster — это оркестратор, предназначенный для организации конвейеров обработки данных: ETL, проведение тестов, формирование отчётов, обучение ML-моделей и т. д. Как и в большинстве других оркестраторов, планирование заданий в нём осуществляется посредством направленного ациклического графа (DAG).

Dagster

Преимущества:

- код на Python
- масштабируемость
- Open Source
- функциональный пользовательский интерфейс
- гибкость настройки ETL и тестирования узлов DAG
- интеграция с экосистемой Hadoop

Недостатки:

- сырой (могут всплывать нетривиальные ошибки)

NiFi

NiFi — это ETL-инструмент с широкими функциональными возможностями по быстрой загрузке и маршрутизации данных любого формата между множеством источников и приёмников информации. Работа с конкретной СУБД реализуется за счёт добавления соответствующего JDBC-драйвера. Есть API для написания своего модуля в качестве дополнительного приёмника или преобразователя данных.

NiFi


Преимущества:

- простой пользовательский интерфейс
- масштабируемость
- Open Source
- широкий функционал для работы с API

Недостатки:

- для расширения функционала требуется знание Java
- слабый механизм логирования работы джобов
- проблемы с надёжностью узла кластера

NiFi



Назначение оркестраторов

SAS

SAS Data Integration Studio — это инструмент визуального проектирования и построения ETL-пайплайнов, внедрения и управления процессами интеграции данных независимо от источников данных, приложений или платформ.

SAS

Преимущества:

- простой пользовательский интерфейс
- масштабируемость
- гибкость
- высокая надёжность

Недостатки:

- собственный язык для написания кода
- требует лицензию и поддержку
- слабая производительность с BigData