


Планировщик Airflow

В ЭТОМ ВИДЕО

- ✓ Более подробно рассмотрите, как работает планировщик
- ✓ Узнаете об особенностях:
 - `execution_date`
 - `backfill`
 - `catchup`
 - `start_date`
 - `end_date`
 - `schedule_interval`

Scheduler

Планировщик — это компонент, который отслеживает DAGs в директории дагов и запускает задачи согласно зависимостям, описанным в Метабазе.




start_date, end_date

Запуски DAG планируются в основном на базе двух параметров: `schedule_interval` и `start_date`. Всякий раз, когда создаётся объект DAG, `schedule_interval` определяется явно или неявно. Значение по умолчанию `schedule_interval` — один день. Это означает, что новые запуски DAG будут планироваться каждый день, начиная со `start_date`. Также можно использовать переменную `end_date`, чтобы указать, когда планировщик прекращает планирование новых запусков DAG. `Start_date` должна быть в прошлом.

Schedule_interval




DagRun, execution_date



Catchup

Планировщик Airflow по умолчанию выполняет запуск DAG для любого интервала, который не был запущен (или был очищен).



backfill

Команда `backfill` позволяет запустить отдельную задачу или DAG для указанного диапазона дат. `backfill` может пригодиться для повторной обработки данных, например, когда после изменения бизнес-логики надо вычислить новую статистику. Для этого в Airflow следует очистить прошлый запуск задачи `calc_statistics` и запустить её снова. Перезапуск будет произведён в независимости от значения параметра `Catchup`.

reRunTasks

Иногда задачи могут завершиться сбоем во время запланированного запуска. Повторный запуск позволяет повторно выполнить неудачные задачи, установив для текущего состояния экземпляра задачи значение `None`. Для автоматического перезапуска достаточно задать параметр `retries` (например, `retries = 3`) и время между перезапусками с помощью параметра `retry_delay` (например, `retry_delay = timestamp.timedelta(minutes = 5)`) либо в операторе, либо в теле дага.

depend_on_past

Иногда необходимо запустить новую задачу, добавленную в существующий DAG, где по умолчанию `depend_on_past` установлен в значение `True`. Эта новая задача не будет запускаться автоматически, и, так как она зависит от прошлого, её невозможно выполнить. Обойти это ограничение можно, установив `depend_on_past = False`, запустив в GUI команду игнорирования зависимостей (Ignore All Deps), отметить предыдущий запуск задачи успешным, даже если фактически она не запускалась, либо использовать `backfill`.