

Поиск аномалий в данных

Поиск аномалий в данных

Цель видео

Научиться искать аномалии в данных.

Поиск аномалий в данных

Аномалии — это наблюдения, которые значительно отличаются от других данных. Они могут указывать на редкие события, ошибки или необычные паттерны.

Основные методы поиска аномалий:

- одноклассовый метод опорных векторов (One-Class SVM)
- изолирующий лес (Isolate Forest)
- Elliptic Envelope и статистические методы
- метрические методы — алгоритмы, такие как k ближайших соседей, ABOD (Angle-Based Outlier Detection) или LOF (Local Outlier Factor)
- кластерные методы

Одноклассовый метод опорных векторов (One-Class SVM)

Этот метод строит нелинейную поверхность вокруг начала координат и позволяет задать границу отсеечения для аномальных данных.

```
from sklearn.svm import OneClassSVM
import numpy as np

# Создаем случайные данные
np.random.seed(42)
X = np.random.randn(100, 2)

# Обучаем One-Class SVM
clf = OneClassSVM(nu=0.05) # nu - параметр аномалий
clf.fit(X)

# Предсказываем аномалии
anomalies = clf.predict(X)
print("Аномалии:", anomalies)
```

Isolate Forest

Этот метод случайным образом строит деревья, что упрощает выделение аномалий на ранних этапах.

```
from sklearn.ensemble import IsolationForest

# Создаем случайные данные
np.random.seed(42)
X = np.random.randn(100, 2)

# Обучаем Isolation Forest
clf = IsolationForest(contamination=0.05) # contamination
clf.fit(X)

# Предсказываем аномалии
anomalies = clf.predict(X)
print("Аномалии:", anomalies)
```

Elliptic Envelope и статистические методы

Этот метод применяется, когда данные нормально распределены. Чем ближе измерение к хвосту смеси распределений, тем более аномальное значение.

```
from sklearn.covariance import EllipticEnvelope

# Создаем случайные данные
np.random.seed(42)
X = np.random.randn(100, 2)

# 00 @final class bool(int) : Envelope
clf = EllipticEnvelope(contamination=0.05) # contamination
clf.fit(X)

# Предсказываем аномалии
anomalies = clf.predict(X)
print("Аномалии:", anomalies)
```