

Выделение по году при чтении

```
silver_df = (spark
    .read
    .load("../sources/data_lake/proc_layer")
    .where("year = 2008"))
```

```
silver_df.show()
```

FBI Code	X Coordinate	Y Coordinate	Updated On	Latitude	Longitude	Location	year
01A	1178207.0	1855308.0	08/17/2015 03:03:...	41.758275857	-87.622451031	(41.758275857, -8...	2008
01A	1144200.0	1895857.0	08/17/2015 03:03:...	41.87025207	-87.746069362	(41.87025207, -87...	2008
01A	1157314.0	1859778.0	08/17/2015 03:03:...	41.770990476	-87.698901469	(41.770990476, -8...	2008
01A	1141065.0	1904824.0	08/17/2015 03:03:...	41.894916924	-87.757358147	(41.894916924, -8...	2008
01A	1154123.0	1886297.0	08/17/2015 03:03:...	41.843826272	-87.709893465	(41.843826272, -8...	2008
01A	1166321.0	1893492.0	08/17/2015 03:03:...	41.863318307	-87.664923682	(41.863318307, -8...	2008
01A	1163192.0	1888742.0	08/17/2015 03:03:...	41.850350125	-87.676543351	(41.850350125, -8...	2008

data_lake

proc_layer

year=2008

year=2009

year=2010

year=2011

Обогащение

Добавление вычисляемой колонки

```
golden_layer = (silver_df
    .withColumn("calculated_column",
                when(col("Arrest"),col("District"))
                  .otherwise(col("Ward")))
    .select("Arrest", "District", "Ward", "calculated_column")
)
```

Arrest	District	Ward	calculated_column
true	3.0	6.0	3.0
true	15.0	24.0	15.0
false	8.0	18.0	18.0
false	15.0	37.0	37.0
false	10.0	22.0	22.0
true	12.0	2.0	12.0
true	10.0	25.0	10.0
false	3.0	5.0	5.0

Агрегации

Самые частые преступления

```
gold_grouped_layer_df = (silver_df
    .groupBy("FBI Code")
    .count()
    .orderBy(col("count").desc())
)
```

+-----+-----+	
FBI Code	count
+-----+-----+	
06	176635
08B	130120
14	105519
26	87643
18	86779
05	52405
08A	38737
07	37707
03	33387
11	24485

Детальный слой данных (Gold Layer)

Итоги

- 1 Узнали нюансы построения детального слоя данных
- 2 Научились строить детальный слой данных