


Построение слоя сырых данных (Bronze Layer)

Цели

- 1 Узнать нюансы построения слоя сырых данных:
 - внешние источники
 - партиционирование
- 2 Научиться наполнять слой сырых данных

Внешние источники

Внешние источники



Extract слабоструктурированных данных из FTP

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.getOrCreate()

ftp_df = spark
.read
.text("ftp://user:pwd/192.168.1.5/increment.csv")

ftp_df.printSchema

root
 |-- value: string (nullable = true)
```

Extract слабоструктурированных данных из S3

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.getOrCreate()

s3_df = spark
    .read
    .text("s3a://bucket_name/increment.csv")

s3_df.printSchema

root
  |-- value: string (nullable = true)
```

Extract слабоструктурированных данных из локальной FS

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.getOrCreate()

lfs_df = spark
.read
.text("file://bucket_name/increment.csv")

lfs_df.printSchema

root
|-- value: string (nullable = true)
```

Extract слабоструктурированных данных из Kafka в реальном времени

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.getOrCreate() kafka_df = spark \
    .readStream \
    .format("kafka") \
    .option("kafka.bootstrap.servers", "localhost:9092") \
    .option("subscribe", "topic_source") \
    .load()

text_df = kafka_df.selectExpr("CAST(value AS STRING)") text_df.printSchema

root
|-- value: string (nullable = true)
```

Extract слабоструктурированных данных из JDBC

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.getOrCreate() jdbc_df = spark \
    .read \
    .format("jdbc") \
    .option("url", "jdbc:mysql://localhost:3306/db_name") \
    .option("dbtable", "table_name") \
    .option("user", "username") \
    .option("password", "password") \
    .load()

jdbc_df.printSchema
root
 |-- value: string (nullable = true)
```

Loading данных в слой сырых данных на HDFS

```
ftp_df  
  .coalesce(1)  
  .write  
  .partitionBy("date")  
  .text("hdfs://nn1home:8020/prod/bronze")
```

Данные не могут быть добавлены в метастор,
сначала их надо провалидировать.

Построение слоя сырых данных (Bronze Layer)

Проверка

```
Hdfs dfs -ls /prod/bronze
```

Построение слоя сырых данных (Bronze Layer)

Итоги

1 Узнали нюансы построения слоя сырых данных:

- внешние источники
- партиционирование

2 Научились наполнять слой сырых данных