

Пошаговое руководство по настройке и использованию Great Expectations с набором данных `crime.csv`

Great Expectations — это инструмент для проверки и документации данных, который помогает обеспечить качество и целостность ваших данных.

Необходимое ПО

- Установленный Python 3.
- Набор данных `crime.csv` в рабочем каталоге.

Установка

Сначала необходимо установить Great Expectations:

```
Unset  
pip3 install great_expectations
```

После установки проверьте версию Great Expectations:

```
Unset  
great_expectations --version
```

Инициализация Great Expectations

Инициализируйте Great Expectations в каталоге проекта. Это создаст необходимые конфигурационные файлы и структуру каталогов.

```
Unset  
great_expectations init
```

Следуйте подсказкам для настройки начальной конфигурации.

Настройка источника данных

Далее настройте новый источник данных. Этот шаг соединяет Great Expectations с данными (crimes.csv).

Unset

```
great_expectations datasource new
```

Следуйте подсказкам, чтобы указать детали вашего набора данных `crime.csv`. Нужно выбрать тип источника данных Pandas и указать путь к вашему CSV-файлу.

Создание нового Expectation Suite

Создайте новый Expectation Suite — набор ожиданий, по которым вы хотите проверять ваши данные.

Unset

```
great_expectations suite new
```

Когда появится запрос, выберите опцию 3 для создания нового Expectation Suite и профилирования автоматически.

После выполнения в интерактивном Jupyter Notebook проверьте появившейся Expectation в папке expectations.

Редактирование Expectation Suite

Отредактируйте недавно созданный Expectation Suite, чтобы добавить пользовательские ожидания. Предположим, что ваш Expectation Suite называется `lab\_set\_of\_expectations`.

Unset

```
great_expectations suite edit lab_set_of_expectations
```

Эта команда откроет интерактивный Jupyter Notebook, где вы можете определить свои ожидания, например:

- Ожидать существования колонок.
- Ожидать, что колонки имеют определённые типы.
- Ожидать, что значения в колонках находятся в определённом диапазоне.

Примеры ожиданий

Вот пример того, как могут выглядеть ваши ожидания в Jupyter Notebook:

Python

```
import great_expectations as ge
```

```

#Загрузка набора данных
df = ge.read_csv('path/to/crime.csv')

# Создание нового DataFrameExpectationSuite
expectation_suite_name = "lab_set_of_expectations"
df_ge = ge.from_pandas(df,
expectation_suite_name=expectation_suite_name)

# Добавление ожиданий
df_ge.expect_column_to_exist('crime_type')
df_ge.expect_column_values_to_be_of_type('crime_date',
'datetime64[ns]')
df_ge.expect_column_values_to_be_between('crime_rate',
min_value=0, max_value=100)

# Сохранение expectation suite
df_ge.save_expectation_suite()

```

Замените ``path/to/crime.csv`` на фактический путь к вашему набору данных. Настройте ожидания в зависимости от конкретных колонок и правил валидации, которые имеют отношение к вашим данным.

Проверка ваших данных

После того как вы определили ожидания, можете проверить ваши данные относительно них. Этот шаг проверяет, соответствуют ли ваши данные определённым ожиданиям.

```

Python
# Загрузка данных и ожиданий
batch = df_ge.get_batch()

# Проверка данных
results = batch.validate()

```

Результаты проверки покажут, соответствуют ли данные вашим ожиданиям, помогая выявить и устранить любые проблемы.

Для получения дополнительных сведений обратитесь [к документации Great Expectations](#).