

Типы источников

Алексей Железной

Data Engineer

Skillbox



Алексей Железной

7+ лет

вовлечён в сферу IT

1 год

опыта преподавания на курсах
Data Engineer и DWH Analyst

3+ лет

коммерческого опыта
в качестве Data Engineer
и Data Analyst

Выпускник

магистратуры НИУ ВШЭ
«Системная и программная
инженерия»

В этом модуле

Вы рассмотрите множество фундаментальных вещей, которые лежат в основе работы с большими данными. Это и различные разновидности источников, и форматы файлов, и работа с БД, в том числе — NoSQL. А самое главное — здесь будет не только теория, но и практика.

Цели модуля

1

Разобрать множество
разновидностей источников

2

Ознакомиться с различными
форматами файлов

3

Изучить модуль языка
программирования Python
под названием PyArrow

4

Познать мир CDC и затронуть
тему NoSQL-баз данных

Типы источников

Разновидности источников

Skillbox

образовательная платформа

Как дела в современном мире?

Содержат базы данных

- ERP
- CRM
- Производственные системы

Также данные хранятся как:

- Отдельные файлы
- Извлечённая информация из IoT


Цель видео

Познакомиться с теоретической информацией по различным типам источников и разобрать практические примеры их использования.


Источники

- Реляционные базы данных
- Плоские файлы
- API и веб-сервисы
- Данные, полученные путём парсинга веб-страниц
- Поток данных или Data Streams


Практический пример





Практический пример




Практический пример



Плоские файлы



Как работает API



API Центробанка

```
{
  "Date": "2022-07-09T11:30:00+03:00",
  "PreviousDate": "2022-07-08T11:30:00+03:00",
  "PreviousURL": "\\./www.cbr-xml-daily.ru/archive/2022/07/08/daily_json.js",
  "Timestamp": "2022-07-10T15:00:00+03:00",
  "Valute": {
    "AUD": {
      "ID": "R01010",
      "NumCode": "036",
      "CharCode": "AUD",
      "Nominal": 1,
      "Name": "Австралийский доллар",
      "Value": 41.8082,
      "Previous": 43.0759
    },
    "AZN": {
      "ID": "R01020A",
      "NumCode": "944",
      "CharCode": "AZN",
      "Nominal": 1,
      "Name": "Азербайджанский манат",
      "Value": 36.0391,
      "Previous": 37.1428
    }
  }
},
```

https://www.cbr-xml-daily.ru/daily_json.js

Парсинг веб-страниц

```
1 import requests
2
3 response = requests.get('https://vk.com/feed?w=wall-46638176_93559').text
4 beginning = response.find('data-post-click-type="post_owner_link" data-post-owner-type="group">') + len
    ('data-post-click-type="post_owner_link" data-post-owner-type="group">')
5 end = response[beginning:].find('</a>')
6 group_name = response[beginning:beginning + end]
7 print(group_name)
```

Хабр Карьера

```
1 requests.get('https://vk.com/feed?w=wall-46638176_93559').text
```

```
<?
<!DOCTYPE html>\n      <html lang="ru" class="vk vk_js_no vk_1x vk_flex_no r d h vk_appAuth
<head>\n          <meta charset="utf-8">\n          <meta name="viewport" content="width=device-width,
maximum-scale=1.0, minimal-ui, user-scalable=no" />\n          <meta name="format-detection" content="telep
http-equiv="X-UA-Compatible" content="IE=edge" />\n          <meta name="MobileOptimized" content="176" />\n
content="True" />\n          <base id="base">\n          \n          <meta name="description" content="«Как мы
<meta property="og:description" content="«Как мы сделали хакатоны great again." />\n          <link rel=
href="/images/icons/favicons/fav_logo.ico?8"></link>\n          <link rel="icon" type="image/png" sizes
href="/images/icons/pwa/favicon_32.png?12">\n          <link rel="apple-touch-icon" href="/images/icons/pwa/app
name="apple-mobile-web-app-title" content="ВКонтакте">\n          <meta name="application-name" content="ВКонта
name="mobile-web-app-capable" content="yes">\n          <meta name="apple-mobile-web-app-status-bar-style" cont
name="theme-color" content="#ffffff">\n<meta name="color-scheme" content="light">\n          <title>«Как мы
Карьера | ВКонтакте</title>\n          <meta http-equiv="origin-trial"
content="Av8ECqeAAIiC9bF3N7aq2M/TaxNzzpPcFXnw0rRb9KRUQlbyHKYmPj6KeVUFVDk
+S7W9RfJH2GsEOs8G99uJvgcAAABaeyJvcmlnaW4iOiJodHRwczovL3ZrLmNvbTo0NDMiLCJmZWFOdXJlIjoiQmFkZ2luZyIsImV4cGly
dWV0">\n          <script nomodule>window nomodules = true;</script>\n          \n          <script>\n
```

Вывод видео

Вы познакомились с разновидностями источников, которые инженеры данных чаще всего используют в своей профессиональной деятельности, разобрали теоретические материалы и практические кейсы.