

Создание ETL-пайплайнов для Greenplum в Airflow

Цели видео




- 1 Повторить необходимые основы ETL, моделирования данных
- 2 Научиться запускать Greenplum из Airflow

Что такое DWH?

1. Построена на основе DB
2. Данные загружаются из источников
3. Из десятков разных источников
4. Данные именно копируются
5. И это исторические данные
6. Периодически копируются
7. Источники всегда **структурированы**



DWH — это модель данных



Оркестрация — это

Процесс автоматизации управления, координации и выполнения различных задач по перекачке, трансформации и сохранению данных из множества источников и хранилищ.

Этот подход позволяет Data Engineer'ам эффективно организовывать сложные рабочие процессы, подбирая наиболее подходящие инструменты для каждой задачи, что в конечном итоге ведёт к успешному выполнению проектов без сорванных дедлайнов и с удовлетворением потребностей бизнес-заказчиков.




MPP — это

Массово-параллельная обработка — это архитектура баз данных, в которой каждый сервер обрабатывает свою часть данных с выделенными ресурсами, поддерживая эффективное партиционирование и индексирование для распределения запросов и обеспечения избыточности данных.




Однако MPP может столкнуться с проблемами неравномерного распределения данных и обработки сложных запросов, а масштабирование может быть затруднено при изменении схемы распределения данных.




Бизнес-домен




Бизнес-домен



Как это всё объединить в ETL?



Создание целевых таблиц



Шаги создания ETL с целевыми таблицами

- 1 Создать и запустить скрипты с целевыми таблицами (разово)
- 2 Написать скрипт наполнения staging-слоя
- 3 Создать DAG и встроить скрипт наполнения

Создание целевых таблиц

```
CREATE TABLE s_aircraft (  
    hk_aircraft BIGINT PRIMARY KEY,  
    load_date_ts TIMESTAMP,  
    aircraft_code VARCHAR(50),  
    model VARCHAR(255),  
    range INT  
) DISTRIBUTED BY (hk_aircraft);
```

```
CREATE TABLE h_aircraft (  
    hk_aircraft BIGINT PRIMARY KEY,  
    load_date_ts TIMESTAMP,  
    aircraft_code VARCHAR(50),  
) DISTRIBUTED BY (hk_aircraft);
```


Построение Airflow-пайплайна

```
from datetime import datetime, timedelta
from airflow import DAG
from airflow.models import Param
from datetime import datetime
from airflow.providers.postgres.operators.postgres import
PostgresOperator
```

```
default_args = {
    'owner': 'airflow',
    'depends_on_past': False,
    'start_date': datetime(2023, 11, 7),
    'email_on_failure': False,
    'email_on_retry': False,
    'retries': 1,
    'retry_delay': timedelta(minutes=5),
}
```

Создание DAG

```
dag = DAG(  
    '112-minio-pxf-greenplum-ddl',  
    params={  
        "greenplum_target_schema": Param("pxf_s3_read_target",  
type="string")  
    },  
    default_args=default_args,  
    schedule_interval='@hourly',  
    catchup=False  
)
```

Создание DAG

```
with dag:
    create_greenplum_table_sql = """
        CREATE TABLE {{ params.schema }}.s_aircraft (
            hk_aircraft BIGINT PRIMARY KEY,
            load_date_ts TIMESTAMP,
            aircraft_code VARCHAR(50),
            model VARCHAR(255),
            range INT
        ) DISTRIBUTED BY (hk_aircraft);
        ...
    """
```

Создание DAG

```
green_plum_if_exists = PostgresOperator(  
    task_id='create_greenplum_table',  
    postgres_conn_id='your_greenplum_connection_id',  
    sql=create_greenplum_table_sql,  
    params={'greenplum_table_name':  
'your_dynamic_table_name'},  
    dag=dag,  
)
```

```
green_plum_if_exists
```

Итоги видео

- 1 Повторили, как моделировать данные в DWH, что такое имплементация и какие есть её варианты в MPP, а также как автоматизировать загрузку данных с помощью оркестрации в Airflow
- 2 Научились запускать Greenplum-скрипты из Airflow