

Этап 1

Основы математики для Data Science

Числа, дроби, функции,
выборка, вероятность, векторы

Абсолютный фундамент

Содержание

1	Натуральные числа, целые числа, арифметика	3
2	Дроби	12
3	Степени, корни и логарифмы	15
4	Проценты и пропорции	18
5	Многочлены, уравнения, неравенства	23
6	Координаты и функции	28
7	Последовательности	29
8	Множества и комбинаторика	30
9	Выборка	32
10	Вероятность	33
11	Векторы	34
12	Задачи	37
13	Разбор задач	40

1–11 — теория и разобранные примеры. 12 — задачи с другими числами. 13 — полные решения, отдельно от условия.

Этап 1. Абсолютный фундамент

Числа, дроби, функции, выборка, вероятность, векторы

1. Натуральные числа, целые числа, арифметика

Прежде чем говорить о модели, нужно уметь считать. Таблица — это сколько строк, сколько столбцов, сколько пустых ячеек, на сколько кусков режем выборку и какой остаток не влез в последний батч¹. Все эти вопросы отвечаются натуральными и целыми числами. Поэтому с них и начинаем: сначала предметы и направление, потом действия, потом признаки делимости.

1.1. Натуральный ряд и целые числа

Представьте кучку камней. Один камень, два, три — это натуральные числа. Ими считают предметы.

$$\mathbb{N} = \{1, 2, 3, \dots\}.$$

Ноль в эту кучку не кладут: ноль камней не считают. Его добавляют следующим шагом. Когда к натуральным присоединяют ноль и числа «в другую сторону», получается прямая целых:

$$\mathbb{Z} = \{\dots, -2, -1, 0, 1, 2, \dots\}.$$

Отрицательное — не «антипредмет», а направление. Долг против актива, убыль против прироста, шаг влево против шага вправо. На прямой ноль — начало отсчёта. Вправо — плюс и больше, влево — минус и меньше. Сравнить число с нулём можно пятью способами: меньше, больше, не больше, не меньше, равно. Ноль сам по себе не положительный и не отрицательный.

Цифра в записи числа стоит в разряде. Разряды группируют в классы по три: единицы, тысячи, миллионы. Это та же идея, что префиксы кило-, мега-, гига-: удобная запись больших количеств.

[в данных] Зачем это нужно

Индекс строки — натуральное число. Размер выборки N — натуральное. Метка класса иногда кодируется целым: -1 и $+1$ в SVM², 0 и 1 в логистической регрессии³. Порядковый номер эпохи⁴, номер фолда⁵, номер батча — снова натуральный ряд. Отрицательные целые появляются как координаты, как центрированные признаки⁶ и как ошибки со знаком. Признак «дни до события» может быть отрицательным: событие уже было. Идентификатор 0 часто означает «значение отсутствует» — тогда ноль уже не количество, а служебная метка.

[задача]

Что просят. Понять, какими числами описана таблица: размер, метки, индексы. Отдельно решить, можно ли ноль считать натуральным номером строки.

¹Порция строк, которую модель обрабатывает за один шаг. Не вся таблица сразу, а кусок фиксированной длины.

²Метод опорных векторов: линейный классификатор, который ищет разделяющую прямую с наибольшим зазором.

³Модель, которая по признакам оценивает вероятность класса и отвечает числом от 0 до 1 .

⁴Один полный проход по всей обучающей выборке.

⁵Доля выборки при проверке: данные режут на k частей, модель учат на $k - 1$ частях и проверяют на оставшейся.

⁶Столбцы таблицы, которые подают модели как вход: возраст, цена, длина сессии.

В таблице 10241 строка. Метки классов записаны как -1 и $+1$. Сколько объектов? Какие из этих меток натуральные, какие целые? Является ли 0 натуральным индексом?

[разбор] Идём по шагам. На бумаге: $N = 10241 \in \mathbb{N}$. Метки лежат в $\mathbb{Z}$, но не в $\mathbb{N}$. Индексы строк $0, 1, \dots, 10240$ — целые неотрицательные; ноль здесь номер, а не количество.

[код]

```
import numpy as np
N = 10241
labels = np.array([-1, 1, 1, -1, 1])
print(N in range(1, 10**9), set(labels))
print(np.arange(N)[:3], "...", np.arange(N)[-1])
```

Что делает код. numpy подключает библиотеку массивов. np.array собирает метки в столбец. range проверяет, лежит ли N среди натуральных. set показывает, какие различные метки встретились. np.arange(N) строит индексы $0, 1, \dots, N - 1$: ноль здесь номер строки, не количество.

1.2. Сложение, вычитание, умножение, деление

Сложить — значит собрать две кучки в одну. То, что складывают, называют слагаемыми, результат — суммой.

Свойство. Переместительное (коммутативность). Порядок слагаемых не важен: $m + n = n + m$. Три плюс пять — те же восемь, что пять плюс три.

Свойство. Сочетательное (ассоциативность). Скобки можно переставлять: $(m + n) + k = m + (n + k)$. Сначала сложили первые два камня или последние — кучка одна.

Свойство. Ноль ничего не меняет: $k + 0 = k$. Это нейтральный элемент сложения.

Вычитание — это сложение с противоположным: $m - n = m + (-n)$. Число, из которого вычитают, называют уменьшаемым, то, что вычитают, — вычитаемым, результат — разностью. Переместительного свойства у вычитания нет: $13 - 5 = 8$, а $5 - 13 = -8$. Это разные точки на прямой.

Свойство. Сложение и вычитание обратны друг другу. Если $m + n = k$, то $k - n = m$, и наоборот. Одно действие проверяет другое.

Умножение — повторное сложение одинаковых слагаемых: три раза по четыре есть $4 + 4 + 4$.

Свойство. У умножения те же два свойства, что у сложения: $mn = nm$ и $(mn)k = m(nk)$. Единица ничего не меняет: $k \cdot 1 = k$. Ноль обнуляет любое произведение: $k \cdot 0 = 0$.

Свойство. Распределительное (дистрибутивность). Умножение раскрывает скобку:

$$a(b + c) = ab + ac.$$

Это то самое правило, которым потом раскрывают многочлен и которым линейная модель собирает вклад признаков: вес на сумму есть сумма весов.

Деление обратно умножению: $k : n = m$ означает $n \cdot m = k$. То, что делят, называют делимым, то, на что делят, — делителем, результат — частным. На ноль делить нельзя. Уравнение $0 \cdot x = k$

при $k \neq 0$ не имеет решения, при $k = 0$ ему подходит любое x . Поэтому запись $k : 0$ не имеет смысла, а $0 : k = 0$ при $k \neq 0$ — обычный ноль.

Порядок действий нужен, чтобы одну и ту же строку все читали одинаково: сначала скобки, потом степень, потом умножение и деление слева направо, потом сложение и вычитание слева направо. Иначе признак $2 + 3 \cdot x^2$ у одного человека станет $(2 + 3) \cdot x^2$, и столбец получится чужой. Проверка на маленьких числах: $2 + 3 \cdot 4^2 - (8 : 2) = 2 + 3 \cdot 16 - 4 = 2 + 48 - 4 = 46$. Сначала степень, затем умножение и деление, затем сложение и вычитание. Если сложить $2 + 3$ раньше времени, получится 80, и это уже другое выражение.

[в данных] Зачем это нужно

Сумма по столбцу — первая агрегация. Разность $y - \hat{y}$ — остаток модели. Произведение $w_j x_j$ — вклад признака в линейную оценку. Частное $TP / (TP + FP)$ — precision⁷. Все четыре действия живут в одной строке отчёта одновременно.

[задача]

Что просят. Сложить три дня, умножить сумму на цену заказа, вычесть второй день из третьего. Затем аккуратно прочесть долю 47 из 50.

Три дня пришло 120, 80 и 100 заказов, каждый заказ даёт 7 единиц. Найдите сумму заказов, выручку и прирост третьего дня ко второму. Отдельно: ассурасу⁸ считают как $47 : 50$. Какая десятичная запись верна — 0,94 или 0,47?

[разбор] Идём по шагам. Сумма $120 + 80 + 100 = 300$, выручка $7 \cdot 300 = 2100$, прирост $100 - 80 = 20$. Частное $47/50 = 0,94$: ошибка разряда 0,47 возникает, если числитель и знаменатель читают как «сотые», а не как долю.

[код]

```
import numpy as np
days = np.array([120, 80, 100])
print(days.sum(), 7 * days.sum(), days[2] - days[1])
print(47 / 50)
```

Что делает код. `np.sum`, `np.prod` складывают и перемножают элементы массива. `np.mean` делит сумму на длину — это среднее, не «сумма как есть».

1.3. Степень как повторное умножение

Пока показатель натуральный,

$$n^k = \underbrace{n \cdot n \cdot \dots \cdot n}_{k \text{ множителей}}$$

Особые случаи: $n^1 = n$, $a^0 = 1$ при $a \neq 0$, символ 0^0 не определяют.

Свойство. Произведение степеней с одним основанием: показатели складывают, $a^m a^n = a^{m+n}$.

Свойство. Частное степеней: показатели вычитают, $a^m / a^n = a^{m-n}$.

⁷Доля верных среди тех объектов, которым модель поставила метку «да».

⁸Доля всех верных ответов модели среди всех объектов.

Свойство. Степень степени: показатели умножают, $(a^m)^n = a^{mn}$.

Свойство. Степень произведения: $a^n b^n = (ab)^n$. Пока показатель натуральный. Позже тот же язык продлится на отрицательные и дробные — правила не меняют формулировку, меняется только область, где они имеют смысл.

[в данных] Зачем это нужно

Размер файла и объём памяти считают степенями двойки: кибибайт, мебибайт. Learning rate⁹ и число параметров сети¹⁰ удобнее читать в стандартном виде, чем длинной записью. Геометрический рост ошибки или капитала — снова степень. Отрицательный показатель и запись $a \cdot 10^k$ — в разделе 3.

[задача]

Что просят. Посчитать две натуральные степени: 2^{10} как размер кибибайта и 7^0 по определению нулевого показателя.

Сколько байт в кибибайте? Чему равно 2^{10} и 7^0 ?

[разбор] Идём по шагам. $2^{10} = 1024$. По определению $7^0 = 1$. Запись шага обучения $3 \cdot 10^{-4}$ и отрицательный показатель — в разделе 3, здесь показатель ещё натуральный.

[код]

```
import math
print(2**10, 7**0)
print(math.pow(2, 10))
```

Что делает код. `**` — возведение в степень. `math.pow(a, b)` делает то же, но всегда возвращает вещественное число, даже если оба аргумента целые.

1.4. Единицы измерения

Приставка 10^n меняет масштаб, не меняя саму величину: это только запись. Кило- увеличивает в тысячу (10^3), мега- — в миллион (10^6), милли- уменьшает в тысячу (10^{-3}), микро- — в миллион (10^{-6}). Площадь переводят квадратом отношения длин: $1 \text{ м}^2 = 10^4 \text{ см}^2$, потому что каждый из двух метров даёт сто сантиметров. Объём — кубом: $1 \text{ м}^3 = 10^6 \text{ см}^3$. Масса идёт теми же степенями десяти: $1 \text{ кг} = 10^3 \text{ г}$. Информация считается двойками: 1 байт = 8 бит, 1 кибибайт = $2^{10} = 1024$ байт, дальше 2^{20} , 2^{30} . Скорость: км/ч в м/с умножают на $5/18$, обратно — на $18/5$. Время: 1 ч = 60 мин = 3600 с. Если в одном столбце часы, а в другом миллисекунды, это не два разных признака качества, а одна величина в двух масштабах.

[в данных] Зачем это нужно

Смешать секунды и миллисекунды в одном столбце — получить признак, который модель прочитает как шум огромного размаха. Timestamp¹¹ в миллисекундах и длительность сессии в секундах нужно привести к одной единице до любого обучения. Килобайт в одном логге и мегабайт в другом — та же ловушка масштаба, что и сырой доход рядом с возрастом.

⁹ Шаг обучения: на сколько сдвигают параметры модели за одну итерацию.

¹⁰ Набор связанных линейных правил с нелинейностями; параметры — числа, которые подбирают по данным.

¹¹ Отметка времени события, обычно число миллисекунд или секунд от фиксированной даты.

[задача]

Что просят. Перевести две величины к другим единицам: миллисекунды в секунды и километры в час — в метры в секунду.

Сессия длилась 45000 миллисекунд. Скорость лога 72 км/ч. Переведите длительность в секунды и скорость в м/с.

[разбор] Идём по шагам. Милли- есть 10^{-3} , поэтому $45000/1000 = 45$ с. Правило км/ч $\rightarrow$ м/с: множитель $5/18$, значит $72 \cdot 5/18 = 20$ м/с.

[код]

```
print(45000 / 1000)
print(72 * 5 / 18)
```

Что делает код. Обычное деление $/$ в Python 3 даёт вещественное частное. Для перевода единиц этого достаточно: масштаб — просто множитель.

1.5. Делимость, простые числа, НОД и НОК

Говорят « n делит m » и пишут $n \mid m$, если m складывается из целого числа кусков длины n : существует целое k с $m = nk$. Делителей у конкретного числа конечное число, кратных ему — бесконечно много.

Свойство. Транзитивность. Если n делит m и m делит ℓ , то n делит ℓ .

Свойство. Сумма двух кратных одному и тому же числу снова ему кратна.

Свойство. В произведении достаточно, чтобы один множитель был кратен: тогда кратно всё произведение.

Признаки делимости экономят разложение: вместо длинного деления смотрят кусок записи. На 2: последняя цифра чётная. На 5: последняя 0 или 5. На 10: последняя 0. На 4: две последние цифры образуют число, делящееся на 4. На 8 — три последние. На 3: сумма цифр делится на 3. На 9: сумма цифр делится на 9. На 11: чередующаяся сумма цифр (плюс, минус, плюс, минус, ...) делится на 11. Пример: 2 574. Сумма цифр 18, значит делится на 3 и на 9. Последняя цифра 4, значит на 2, и две последние $74 = 2 \cdot 37$ — на 4. На 5 не делится. Чередующаяся сумма $2 - 5 + 7 - 4 = 0$ делится на 11, значит $2574 : 11 = 234$.

Простое число имеет ровно два натуральных делителя: единицу и себя. Единица не простое и не составное: у неё один делитель. Чтобы проверить n на простоту, достаточно испытать простые делители до $\sqrt{n}$: дальше частное уже меньше делителя.

Свойство. Основная теорема арифметики. Всякое $n > 1$ единственным образом, с точностью до порядка множителей, есть произведение степеней простых. По этой записи проверяют делимость, собирают НОД как минимум показателей и НОК как максимум.

Алгоритм Евклида считает НОД без полной факторизации:

$$\text{НОД}(a, b) = \text{НОД}(b, a \bmod b)$$

пока остаток не станет нулём. Последний ненулевой остаток и есть НОД.

Два числа взаимно просты, если их НОД равен 1. Так бывают и два простых, и два составных: 8 и 15 составные, а общий делитель у них только единица. Если число делится на каждое из двух взаимно простых, оно делится на произведение: на 2 и на 3 — значит на 6; на 3 и на 4 — на 12; на 3 и на 5 — на 15. На 4 и на 6 — ещё не значит на 24: эти два не взаимно просты, и 12 делится на оба, но не на 24.

Деление с остатком: для $n \neq 0$ существуют единственные q и r с

$$m = nq + r, \quad 0 \leq r < |n|.$$

В коде это `//` и `%`.

Факториал $n! = 1 \cdot 2 \cdot \dots \cdot n$, $0! = 1$, и $n! = n \cdot (n-1)!$. Он понадобится в сочетаниях.

[в данных] Зачем это нужно

Батч длины B при выборке длины N даёт $N \operatorname{div} B$ полных кусков и хвост $N \bmod B$. Хвост не исчезает сам: его отбрасывают, дополняют или прогоняют отдельно. Номер объекта по модулю k раскладывает строки по k фолдам без пересечения, если идентификаторы целые и распределение равномерное. Чётность иногда сама становится признаком: день недели, час, флаг «корзина чётной длины».

[задача]

Что просят. Разделить длину таблицы на длину батча с остатком: найти полное частное, хвост и долю хвоста. Затем сказать, что ломается, если хвост просто выкинуть.

Длина выборки $N = 2350$, длина батча $B = 128$. Сколько полных батчей и каков хвост? Что будет, если хвост выбросить?

[разбор] Идём по шагам. $2350 = 128 \cdot 18 + 46$: восемнадцать полных батчей и хвост из сорока шести строк. Доля хвоста $46/2350 = 23/1175 \approx 0,02$. Если хвост молча выбросить, теряется два процента данных; если оставить как есть, последний градиент¹² считается по другой длине и его нельзя сравнивать с предыдущими без пересчёта.

[код]

```
N, B = 2350, 128
print(N // B, N % B, (N % B) / N) # полное частное, хвост, доля хвоста
```

Что делает код. `//` — целое частное (сколько полных батчей). `%` — остаток (длина хвоста). Вместе они и есть деление с остатком $N = qB + r$.

[задача]

Что просят. Сократить каждую дробь через НОД числителя и знаменателя, затем найти НОК новых знаменателей — это и будет общий знаменатель.

Даны дроби $\frac{56}{189}$ и $\frac{110}{360}$. Сначала сократите каждую, затем возьмите НОК знаменателей.

¹² Вектор направления наискорейшего роста функции ошибки. По нему шагают при обучении.

[разбор] Идём по шагам. Евклид для числителя и знаменателя первой дроби:

$$189 = 3 \cdot 56 + 21, \quad 56 = 2 \cdot 21 + 14, \quad 21 = 1 \cdot 14 + 7, \quad 14 = 2 \cdot 7 + 0.$$

НОД равен 7, поэтому $\frac{56}{189} = \frac{8}{27}$. Вторая дробь:

$$360 = 3 \cdot 110 + 30, \quad 110 = 3 \cdot 30 + 20, \quad 30 = 1 \cdot 20 + 10, \quad 20 = 2 \cdot 10 + 0.$$

НОД равен 10, поэтому $\frac{110}{360} = \frac{11}{36}$. Канонически $27 = 3^3$, $36 = 2^2 \cdot 3^2$, значит

$$\text{НОК}(27, 36) = 2^2 \cdot 3^3 = 108.$$

Дополнительные множители $108 : 27 = 4$ и $108 : 36 = 3$:

$$\frac{8}{27} = \frac{32}{108}, \quad \frac{11}{36} = \frac{33}{108}.$$

Сумма, если она нужна, равна $\frac{65}{108}$. Именно так на бумаге ищут общий знаменатель: сократить, разложить, взять максимумы показателей.

[код]

```
from math import gcd
from sympy import Rational, ilcm
print(gcd(56, 189), Rational(56, 189)) # НОД и уже сокращённая дробь
print(gcd(110, 360), Rational(110, 360))
print(ilcm(27, 36)) # общий знаменатель
print(Rational(56, 189) + Rational(110, 360))
```

Что делает код. `math.gcd` считает НОД алгоритмом Евклида. `sympy.Rational` хранит дробь без округления. `ilcm` берёт НОК. Сумма двух `Rational` сама сокращается.

1.6. Модуль и чётность

Модуль $|a|$ — расстояние от числа до нуля на прямой. Расстояние не бывает отрицательным.

Свойство. Неравенство треугольника: $|a + b| \leq |a| + |b|$. Обход через две палки не короче прямого пути. Числа с равным модулем и разными знаками противоположны, их сумма равна нулю: они взаимно уничтожаются в алгебраической сумме. Чётное число делится на 2, нечётное даёт остаток 1.

Сложение целых: одинаковые знаки — складывают модули и ставят общий знак; разные — из большего модуля вычитают меньший и ставят знак большего. Умножение и деление: чётное число минусов даёт плюс, нечётное — минус. Степень отрицательного основания отрицательна при нечётном показателе и положительна при чётном; без скобок $-2^4 = -(2^4) = -16$, со скобками $(-2)^4 = 16$. Минус перед скобкой меняет все знаки внутри: $-(a - b) = -a + b$. Плюс перед скобкой знаки не трогает. Это то же правило, которым потом раскрывают многочлен.

[в данных] Зачем это нужно

Сумма $|y_i - \hat{y}_i|$ есть MAE¹³. Сумма квадратов тех же разностей есть MSE¹⁴: другая геометрия на той же прямой. Порог $|z| > 3$ после стандартизации¹⁵ отсекает грубые выбросы. Чётность индекса используют, когда режут последовательность через один элемент.

[задача]

Что просят. По одной и той же тройке остатков посчитать две меры ошибки: среднее модулей и среднее квадратов.

Остатки модели 2, −7, 0. Найдите MAE и MSE.

[разбор] Идём по шагам. $MAE = \frac{|2| + |-7| + |0|}{3} = \frac{9}{3} = 3$. $MSE = \frac{4 + 49 + 0}{3} = \frac{53}{3}$. Одна и та же тройка остатков, две разные геометрии: модуль и квадрат.

[код]

```
import numpy as np
r = np.array([2.0, -7.0, 0.0])
print(np.abs(r).mean(), (r**2).mean())
```

Что делает код. `np.abs` берёт модуль каждого остатка. `mean` усредняет: так получают MAE. Квадрат и `mean` дают MSE.

1.7. Знаки целых, скобки, степень отрицательного

Целые уже введены как прямая со стрелкой. Здесь — как с ними считать, когда минусов несколько.

Любое выражение из плюсов и минусов можно записать как алгебраическую сумму: вычесть b значит прибавить $-b$.

Свойство. Правило сложения по модулям. Если знаки одинаковые, складывают модули и оставляют общий знак: $-7 + (-5) = -12$. Если знаки разные, из большего модуля вычитают меньший и ставят знак большего: $-7 + 5 = -2$, а $-5 + 7 = 2$. Сумма противоположных всегда ноль: $512 - 512 = 0$, поэтому в длинной сумме такие пары вычёркивают сразу.

Минус перед скобкой меняет каждый знак внутри: $-(a - b) = -a + b$. Плюс перед скобкой ничего не трогает. Знака нет — подразумевается плюс.

Свойство. Знак произведения и частного. Одинаковые знаки дают плюс, разные — минус. Нечётное число минусов в произведении оставляет минус, чётное — плюс.

Отсюда же степень отрицательного. Скобки решают, куда относится минус:

$$(-2)^4 = 16, \quad -2^4 = -16.$$

Слева минус входит в основание и повторяется четыре раза. Справа сначала считают 2^4 , потом ставят минус.

¹³Mean Absolute Error: среднее модулей остатков $y - \hat{y}$.

¹⁴Mean Squared Error: среднее квадратов остатков. Сильнее штрафует большие промахи, чем MAE.

¹⁵Вычитание среднего и деление на разброс: столбец приводят к нулевому центру и единичному масштабу.

Деление по знаку ведёт себя как умножение. Но деление *не* раскрывает скобку так, как умножение: $c : (a + b)$ не равно $c : a + c : b$.

[в данных] Зачем это нужно

Центрированный признак $x - \bar{x}$ бывает отрицательным — это не ошибка знака, а положение относительно среднего. Остаток $y - \hat{y}$ тоже со знаком: недооценка и переоценка — разные стороны. Путать $(-2)^4$ и -2^4 в формуле признака значит получить столбец другого знака и другую модель.

[задача]

Что просят. Посчитать алгебраическую сумму по правилу модулей и отличить $(-3)^2$ от -3^2 .

Вычислите $-18 + 7 - (-5)$ и сравните $(-3)^2$ с -3^2 .

[разбор] Идём по шагам. $-18 + 7 = -11$, затем $-11 + 5 = -6$. $(-3)^2 = 9$, потому что минус в основании. $-3^2 = -9$, потому что степень только у тройки.

[код]

```
print(-18 + 7 - (-5))
print((-3)**2, -3**2)
```

Что делает код. `**` сильнее унарного минуса: `-3**2` читается как `-(3**2)`. Скобки в `(-3)**2` загоняют минус в основание.

1.8. Округление

Округление до данного разряда смотрит на следующую цифру. Если она 0, 1, 2, 3, 4 — оставляют как есть. Если 5, 6, 7, 8, 9 — разряд увеличивают на единицу. Цифры правее отбрасывают.

3,14159 до сотых: следующая цифра 1, поэтому 3,14. До тысячных: следующая 5, поэтому 3,142.

В данных округление — уже потеря точности. Для денег обычно держат два знака, для вероятности — больше. Округлять промежуточный счёт и только потом агрегировать — значит сложить ошибки. Сначала считают точно, округляют ответ.

[задача]

Что просят. Округлить одно число до двух разных разрядов и увидеть, что ответы разные.

Округлите 2,375 до десятых и до сотых.

[разбор] Идём по шагам. До десятых: смотрят на $7 \geq 5$, получается 2,4. До сотых: смотрят на $5 \geq 5$, получается 2,38.

[код]

```
print(round(2.375, 1), round(2.375, 2))
```

Что делает код. `round(x, n)` округляет до n знаков после запятой. Правило для пятёрки в Python может отличаться от школьного «от 5 вверх»: для банки лучше считать сами.

Задачи к этому разделу — пункты 1.1–1.11 в §12. Решения — в §13.

2. Дроби

Целыми числами удобно считать штуки. Как только появляется часть целого — половина класса, треть пропусков, вес объекта меньше единицы — целых перестаёт хватать. Дробь как раз и есть эта часть. Сначала обыкновенная запись a/b , потом десятичная, потом то, как машина хранит дробь и почему $0,1 + 0,2$ не равно $0,3$.

2.1. Обыкновенная дробь и поле рациональных

Дробь a/b с натуральным знаменателем есть класс пар с правилом

$$\frac{a}{b} = \frac{c}{d} \iff ad = bc.$$

Свойство. Основное свойство дроби. Числитель и знаменатель можно умножить или разделить на одно и то же натуральное число — величина не изменится. Сокращение и расширение — два направления одного правила. Сокращение — деление на $\text{НОД}(|a|, b)$. Правильная дробь меньше единицы по модулю, неправильная — не меньше, смешанная выделяет целую часть.

Сложение требует общего знаменателя:

$$\frac{a}{b} \pm \frac{c}{d} = \frac{ad \pm bc}{bd}.$$

Знаменатель bd всегда подходит, но часто слишком большой. Берут НОК знаменателей — тот же приём, что в разделе 1 для $8/27$ и $11/36$: сократили каждую дробь, разложили знаменатели, взяли максимумы показателей. После сложения результат снова сокращают. Умножение прямое, деление — умножение на обратную:

$$\frac{a}{b} \cdot \frac{c}{d} = \frac{ac}{bd}, \quad \frac{a}{b} : \frac{c}{d} = \frac{a}{b} \cdot \frac{d}{c} = \frac{ad}{bc}.$$

Так $\mathbb{Q}$ становится полем: делить можно на всё, кроме нуля. Сравнение дробей с разными знаменателями сводят к сравнению числителей после приведения, либо смотрят на знак $ad - bc$. При равных знаменателях больше та, у которой больше числитель; при равных числителях больше та, у которой меньше знаменатель. Нечётное число минусов в записи делает дробь отрицательной, чётное — положительной.

Часть числа p/q от величины A есть произведение $\frac{p}{q}A$. Наоборот, если известна часть и доля, целое восстанавливают делением.

Неправильную дробь в смешанное переводят делением с остатком: неполное частное — целая часть, остаток — новый числитель. Обратное: целую часть умножают на знаменатель и прибавляют числитель.

[задача]

Что просят. Два перевода записи дроби и две обратные задачи на часть числа: от числа к части и от части к целому.

Переведите $\frac{17}{5}$ в смешанное число и $2\frac{3}{7}$ в неправильную. Какую часть составляет $\frac{2}{3}$ от 48, и какое целое, если $\frac{2}{3}$ его равны 48?

[разбор] Идём по шагам. $17 = 5 \cdot 3 + 2$, значит $\frac{17}{5} = 3\frac{2}{5} \cdot 2\frac{3}{7} = \frac{2 \cdot 7 + 3}{7} = \frac{17}{7}$. Часть от числа: $\frac{2}{3} \cdot 48 = 32$. Число по части: $48 : \frac{2}{3} = 72$.

[код]

```
from sympy import Rational
print(divmod(17, 5), Rational(2*7 + 3, 7))
print(Rational(2, 3) * 48, 48 / Rational(2, 3))
```

Что делает код. `Rational(p, q)` строит обыкновенную дробь и сразу сокращает. Смешанное число собирают как целое плюс дробная часть.

2.2. Десятичная дробь

Десятичная запись — дробь со знаменателем 10^k . Конечная десятичная получается тогда, когда канонический знаменатель содержит только 2 и 5. Иначе появляется период: $1/3 = 0,(3)$, $1/7 = 0,(142857)$. Период переводят сдвигом запятой и вычитанием: множитель 10^ℓ , где ℓ — длина периода, снимает повторяющийся хвост. Округление до k знаков смотрит на следующий разряд: 18,46 до десятых есть 18,5, 9,95 до целых есть 10. Сравнение десятичных выравнивает число знаков нулями справа: $4,08 < 4,80$. Период не сразу после запятой сдвигают на число цифр до периода и на длину периода: для $x = 0,1(6)$ берут $10x = 1,(6)$ и $100x = 16,(6)$, разность $90x = 15$, $x = 1/6$.

Сравнивать и складывать конечные десятичные удобнее в десятичной записи; если в сумме есть период, все слагаемые лучше вернуть к обыкновенным. Машинный `float` хранит не десятичную дробь, а двоичную. Число 0,1 в двоичной записи периодическое, поэтому $0.1 + 0.2 == 0.3$ ложно. Это не баг языка, а прямое следствие того, какие дроби двоично-конечны.

[задача]

Что просят. Период превратить в обыкновенную дробь сдвигом и вычитанием. Затем сложить две обыкновенные через общий знаменатель.

Переведите $0,(4)$ в обыкновенную дробь и сложите $\frac{3}{8} + \frac{1}{6}$.

[разбор] Идём по шагам. Пусть $x = 0,(4)$. Тогда $10x = 4,(4)$, разность $9x = 4$, $x = 4/9$. Общий знаменатель 24: $\frac{9}{24} + \frac{4}{24} = \frac{13}{24}$. Сравнение `float` и перевод $0,1(6)$ — в абзаце выше и в упражнении 2.3, 2.6: здесь достаточно одного периода и одного сложения.

[код]

```
from fractions import Fraction
from sympy import Rational
print(Fraction(4, 9), Rational(3, 8) + Rational(1, 6))
```

Что делает код. `fractions.Fraction` — стандартная точная дробь Python. У `float` период $0,(3)$ уже обрезан, поэтому $0.1+0.2$ не равно 0.3 .

2.3. [в данных] Зачем это нужно

Почти любая метрика — дробь. Accuracy и precision уже появились как частные в разделе 1; рядом с ними стоит recall¹⁶ — пойманные плюсы/все истинные плюсы. Доля класса в несбалансированной задаче есть n_1/N . Train/validation/test¹⁷ режут тремя дробями с суммой единица. Конкретную нарезку считают пропорцией в разделе 4.

Взвешенное среднее

$$\frac{w_1x_1 + \dots + w_mx_m}{w_1 + \dots + w_m}$$

есть дробь: знаменатель помнит размеры групп, поэтому полусумма средних двух выборок разной длины не равна общему среднему. Та же арифметика, что у смешения растворов.

[задача]

Что просят. Из процента получить число пустых строк и долю заполненных. Затем найти взвешенное среднее двух групп разного размера — не полусумму.

В таблице 2500 строк пропусков 12%. Сколько пустых строк и какова доля заполненных? Десять наблюдений со средним 4 и тридцать со средним 3: какое общее среднее?

[разбор] *Идём по шагам.* Пустых $0,12 \cdot 2500 = 300$, заполненных 2200, доля $2200/2500 = 11/25 = 0,88$. Взвешенное среднее $\frac{10 \cdot 4 + 30 \cdot 3}{40} = 3,25$, а не полусумма 3,5: знаменатель помнит размеры групп. Долю верных ответов и восстановление целого по части оставляем упражнениям 2.5 и 2.7; скидку — разделу про проценты.

[код]

```
from sympy import Rational
print(Rational(12, 100) * 2500)
print(Rational(10*4 + 30*3, 40))
```

Что делает код. Снова Rational: период переводят в обыкновенную дробь на бумаге, библиотека проверяет тот же ответ.

2.4. Сравнение дробей и действия по шагам

Сравнение уже следует из основного свойства: $\frac{a}{b}$ и $\frac{c}{d}$ сравнивают по знаку $ad - bc$ или приводят к общему знаменателю. При равных знаменателях больше дробь с большим числителем: $\frac{5}{7} > \frac{3}{7}$. При равных числителях больше та, у которой знаменатель меньше: $\frac{3}{5} > \frac{3}{8}$, потому что пирог режут на меньшее число кусков.

Сложение на бумаге: сначала сокращают каждую дробь, затем берут НОК знаменателей, домножают, складывают числители, снова сокращают. Умножение — числитель на числитель, знаменатель на знаменатель, потом сокращение крест-накрест, если можно. Деление — умножение на перевёрнутую вторую дробь. Делить на ноль по-прежнему нельзя.

Смешанное число $n\frac{p}{q}$ есть $n + \frac{p}{q}$. В действиях его почти всегда переводят в неправильную, считают, и только ответ при желании возвращают в смешанную запись.

¹⁶ Доля пойманных истинных «да» среди всех истинных «да».

¹⁷ Три доли таблицы: на первой модель учат, на второй подбирают настройки, на третьей один раз проверяют итог.

[в данных] Зачем это нужно

Сравнить $3/8$ и 36% в отчёте можно, только приведя оба к одному языку: $0,375$ и $0,36$. Иначе «больше» зависит от записи, а не от величины.

[задача]

Что просят. Сравнить дробь с процентом через десятичную запись и сложить две дроби через НОК, не через произведение знаменателей вслепую.

Что больше: $\frac{3}{8}$ или 36% ? Чему равна $\frac{5}{12} + \frac{7}{18}$?

[разбор] Идём по шагам. $\frac{3}{8} = 0,375$, $36\% = 0,36$, значит дробь больше. Знаменатели $12 = 2^2 \cdot 3$ и $18 = 2 \cdot 3^2$, НОК $= 2^2 \cdot 3^2 = 36$. $\frac{15}{36} + \frac{14}{36} = \frac{29}{36}$.

[код]

```
from sympy import Rational, ilcm
print(float(Rational(3, 8)), 0.36)
print(ilcm(12, 18), Rational(5, 12) + Rational(7, 18))
```

Что делает код. `float` переводит точную дробь в десятичную, чтобы сравнить с процентом. `ilcm` берёт НОК знаменателей. `Rational` складывает без округления и сам сокращает.

Задачи — пункты 2.1–2.8 в §12.

3. Степени, корни и логарифмы

Степень, корень и логарифм — три способа сказать одно и то же про пару чисел: «это столько-то раз умножили само на себя». Пока три записи не связаны, каждая новая кажется отдельным фокусом. Свяжем их и посмотрим, зачем такая шкала в данных.

3.1. Отрицательный и дробный показатель

Натуральная степень и четыре правила показателей уже были в разделе 1; нуль в показателе там же: $a^0 = 1$ при $a \neq 0$. Отрицательная определяется так, чтобы то же правило $a^m a^n = a^{m+n}$ осталось верным:

$$a^{-n} = \frac{1}{a^n} \quad (a \neq 0).$$

Корень есть обратная операция к возведению в степень:

$$\sqrt[n]{a} = a^{1/n},$$

и тогда рациональный показатель $a^{p/q} = \sqrt[q]{a^p}$ согласован со всеми тождествами там, где выражение определено. Для чётного знаменателя в вещественных числах основание неотрицательно. Если корень не извлекается нацело, число иррационально: оно лежит в $\mathbb{R} \setminus \mathbb{Q}$. Множество действительных $\mathbb{R}$ как раз и закрывает такие величины вместе с пределами последовательностей. Корень из суммы не равен сумме корней; путать $\sqrt{a+b}$ и $\sqrt{a} + \sqrt{b}$ нельзя.

[задача]

Что просят. Посчитать отрицательную степень и кубический корень. Затем сравнить корень из суммы с суммой корней и увидеть, что это разные вещи.

Вычислите 5^{-2} и $\sqrt[3]{27}$. Почему $\sqrt{16+9}$ не равно $\sqrt{16} + \sqrt{9}$?

[разбор] Идём по шагам. $5^{-2} = 1/25$. Куб $3^3 = 27$, поэтому $\sqrt[3]{27} = 3$. Слева $\sqrt{25} = 5$, справа $4 + 3 = 7$. Корень не дистрибутивен по сложению.

[код]

```
import math
from sympy import Integer, Pow, Rational as Q
print(5**(-2), 27**(1/3), math.isclose(27**(1/3), 3))
print(math.sqrt(16+9), math.sqrt(16)+math.sqrt(9))
print(Pow(Integer(27), Q(1, 3)))
```

Что делает код. $**(-2)$ — отрицательная степень, то есть единица на квадрат. $27**(1/3)$ в вещественных числах приближает корень; `math.isclose` сравнивает с запасом на округление. `sympy.Pow` с `Rational` держит корень точно.

3.2. Логарифм

$\log_a b = c$ означает ровно $a^c = b$, где $a > 0$, $a \neq 1$, $b > 0$.

Три языка:

$$b = a^c \iff c = \log_a b \iff a = \sqrt[c]{b}.$$

Из свойств степени сразу получаются свойства логарифма — это не новый список, а тот же набор, переписанный на другом языке.

Свойство. Логарифм произведения есть сумма логарифмов: $\log_a(xy) = \log_a x + \log_a y$.

Свойство. Логарифм частного есть разность: $\log_a(x/y) = \log_a x - \log_a y$.

Свойство. Показатель выносится: $\log_a(x^p) = p \log_a x$.

Свойство. Замена основания: $\log_a b = \log_c b / \log_c a$. Через это любой логарифм считают как $\ln$ или $\log_{10}$.

[задача]

Что просят. Сложить два логарифма с одним основанием по свойству произведения и узнать получившуюся степень четвёрки.

Сверните $\log_4 8 + \log_4 2$ в одно число.

[разбор] Идём по шагам. Сумма логарифмов есть логарифм произведения: $\log_4(8 \cdot 2) = \log_4 16$. Поскольку $4^2 = 16$, значение равно 2.

[код]

```
import math
from sympy import log
print(math.log(8, 4) + math.log(2, 4))
```



```
print(log(16, 4))
```

Что делает код. `math.log(x, a)` — логарифм x по основанию a . `sympy.log` делает то же символом и умеет упрощать сумму в одно число.

3.3. Стандартный вид

Число записывают как $a \cdot 10^k$, где $1 \leq |a| < 10$, $k \in \mathbb{Z}$. Так сравнивают порядки: $3,2 \cdot 10^5$ больше $4,1 \cdot 10^4$, потому что показатель больше. Слагаемые с разными порядками сначала приводят к меньшей степени, складывают мантиссы и при необходимости снова нормализуют: $2,1 \cdot 10^5 + 3,4 \cdot 10^4 = 2,1 \cdot 10^5 + 0,34 \cdot 10^5 = 2,44 \cdot 10^5$. На данных это запись очень больших и очень маленьких величин без длинного хвоста нулей.

[задача]

Что просят. Переписать два числа как $a \cdot 10^k$ с одной цифрой до запятой. Сравнить вторую пару по показателю, а не по мантиссе.

Запишите 0,00072 и 45000 в стандартном виде. Что больше: $3,2 \cdot 10^5$ или $4,1 \cdot 10^4$?

[разбор] Идём по шагам. $0,00072 = 7,2 \cdot 10^{-4}$, $45000 = 4,5 \cdot 10^4$. Порядок 5 больше порядка 4, поэтому $3,2 \cdot 10^5 > 4,1 \cdot 10^4$, хотя мантисса слева меньше.

[код]

```
print(0.00072, 7.2 * 10**(-4))
print(3.2 * 10**5 > 4.1 * 10**4)
```

Что делает код. Обычная запись $7.2 * 10^{**}(-4)$ и есть стандартный вид. Само число 0.00072 машина уже хранит так внутри.

3.4. [в данных] Зачем это нужно

Доходы $3 \cdot 10^4$ и $3 \cdot 10^6$ на линейной оси схлопывают маленькие значения в ноль. Логарифм переводит их в 4,48 и 6,48: порядки становятся расстоянием. Счётчики событий часто заменяют на $\log(1+x)$. Сдвиг на единицу определён в нуле и почти не трогает большие x .

Сложный процент есть $S_n = S_0(1+r)^n$. Время удвоения

$$n = \log_{1+r} 2 = \frac{\ln 2}{\ln(1+r)}.$$

Шаг обучения в стандартном виде уже появлялся в разделе 1; здесь важен логарифм как шкала порядков. Логарифмическая потеря¹⁸ растёт без верхней границы, когда модель уверена не в том классе.

[задача]

Что просят. Решить неравенство $1,1^n > 2$ через логарифм и проверить соседние целые степени.

Сколько раз нужно умножить капитал на 1,1, чтобы он удвоился?

¹⁸Штраф — $\log p$, где p — вероятность, которую модель дала истинному классу. Чем ближе p к нулю, тем штраф больше.

[разбор] Идём по шагам. Неравенство $1,1^n > 2$ равносильно $n > \ln 2 / \ln 1,1 \approx 7,27$, значит восемь раз. Проверка: $1,1^7 \approx 1,95$, $1,1^8 \approx 2,14$. Упрощение буквенной степени и сумму логарифмов уже разбирали выше — в лист задач ставим другие основания.

[код]

```
import math
print(math.log(2) / math.log(1.1))
print(1.1**7, 1.1**8)
```

Что делает код. `math.log` без второго аргумента — натуральный логарифм. Сдвиг `log(1+x)` нужен, чтобы ноль в данных не ломал логарифм.

Буквенное упрощение $\frac{(x^3)^{-4}}{x^{-3}} = x^{-9}$ и столбец $\log_{10}(1+x)$ — упражнения 3.1 и 3.5: в теории достаточно одного числового логарифма и одного корня.

Задачи — пункты 3.1–3.5.

4. Проценты и пропорции

Процент — сотая часть числа:

$$p\% = \frac{p}{100}.$$

Сама величина процента неотрицательна: $0\% \leq p$. Уменьшение записывают словами «на $x\%$ », а не знаком минус у процента. Доля и процент — одна и та же дробь в двух шкалах: долю умножили на 100 — получили процент, процент разделили на 100 — вернули долю. Чтобы сравнить обыкновенную дробь и процент, оба переводят в десятичную: $\frac{1}{4} = 0,25$ и $20\% = 0,2$, поэтому $\frac{1}{4} > 20\%$.

Три типовые задачи отличаются только тем, что неизвестно. Процент от числа: $\frac{p}{100}b$. Число по проценту: если $\frac{p}{100}x = a$, то $x = \frac{100a}{p}$. Какую долю составляет a от b : $\frac{a}{b} \cdot 100\%$. Удобные доли на бумаге: 1% — деление на 100, 10% — на 10, 50% — пополам, 25% — четверть, 5% — половина от десяти, 2,5% — половина от пяти.

Увеличить на $p\%$ — умножить на $1 + \frac{p}{100}$. Уменьшить на $p\%$ — умножить на $1 - \frac{p}{100}$. Если известна уже изменённая величина, исходную получают делением на тот же множитель: после скидки 20% платят 480, было $480/0,8 = 600$.

4.1. Последовательные изменения и два языка роста

После каждого шага за 100% берут уже новое значение. Показатели нельзя складывать. Сначала +20%, затем −20% дают

$$a \cdot \frac{100 + 20}{100} \cdot \frac{100 - 20}{100} = a \cdot \frac{100^2 - 20^2}{100^2} = 0,96a,$$

а не исходное число. Два роста по $y\%$ — это не рост на $2y\%$:

$$\left(1 + \frac{y}{100}\right)^2 = 1 + \frac{2y}{100} + \left(\frac{y}{100}\right)^2.$$

Квадратичный хвост — тот же, что появится у сложного процента.

Рост метрики нужно уметь сказать двумя языками, и их нельзя путать. Разность двух долей измеряется в процентных пунктах¹⁹. Отношение этой разности к исходной базе — относительный рост в процентах. С 0,62 до 0,71 есть девять пунктов и

$$\frac{0,71 - 0,62}{0,62} \approx 14,5\%$$

относительно базы. В отчёте пишут обе величины; одна без другой врёт масштабом.

Простой процент каждый раз начисляют на исходную сумму: $S_n = S_0(1 + rn)$. Сложный — на уже новую: $S_n = S_0(1 + r)^n$. Капитализация m раз в год заменяет год на m шагов со ставкой r/m . Тот же множитель $(1 + r)^n$ описывает затухание веса в экспоненциальном сглаживании: там r отрицателен и пишут $(1 - \alpha)^t$. Равный платёж по кредиту (аннуитет) — частный случай геометрической прогрессии: каждая выплата гасит и проценты на остаток, и кусок долга; формулу целиком здесь не разворачиваем.

[задача]

Что просят. Посчитать сумму вклада двумя способами — простой и сложный процент. Отдельно перевести рост метрики в пункты и в относительные проценты и не смешать эти два языка.

Вклад 50 000 на три года под 8%. Сравните простой и сложный процент. Рост метрики 0,62 → 0,71 запишите в пунктах и в относительных процентах.

[разбор] *Идём по шагам.* Простой: $50000(1 + 0,08 \cdot 3) = 62000$. Сложный: $50000 \cdot 1,08^3 = 62985,6$. Разница 985,6 есть процент на уже начисленные проценты. Рост метрики: девять пунктов и $0,09/0,62 \approx 14,5\%$. Множители $1,2 \cdot 0,8 = 0,96$ из абзаца выше — другое явление, чем вклад: там два шага в разные стороны, здесь один множитель повторяется три раза.

[код]

```
print(50000 * (1 + 0.08 * 3), 50000 * 1.08**3)
print(0.71 - 0.62, (0.71 - 0.62) / 0.62)
```

Что делает код. * и ** — обычные умножение и степень. Простой процент линейный, сложный — геометрический: отсюда разница двух формул.

4.2. Смесь двух групп

Концентрация раствора — снова доля:

$$c = \frac{m_{\text{вещества}}}{m_{\text{смеси}}}$$

Сухое вещество не уходит, вода уходит: масса смеси падает, концентрация растёт. Если смешали две группы разного размера, концентрация смеси — взвешенное среднее долей, а не полусумма. Смешали 3 кг раствора 10% и 2 кг раствора 25%: вещества $0,3 + 0,5 = 0,8$ кг на 5 кг смеси, доля $0,16 = 16\%$, а не среднее арифметическое 17,5%. В таблице это ровно объединение двух выборок: доля положительного класса в склейке считается по сумме единиц и сумме строк, а не полусуммой двух ассигасу.

¹⁹ Абсолютная разность двух процентов: $71\% - 62\% = 9$ пунктов. Это не то же самое, что относительный рост на девять процентов.

[задача]

Что просят. Найти число положительных в каждой группе, сложить их, сложить длины и разделить. Не брать полусумму долей.

Смешали выборку из 300 строк с долей положительного класса 0,10 и выборку из 200 строк с долей 0,25. Какая доля в объединении?

[разбор] Идём по шагам. Положительных $0,10 \cdot 300 + 0,25 \cdot 200 = 30 + 50 = 80$. Строк 500. Доля $80/500 = 0,16 = 16\%$.

[код]

```
print((0.10 * 300 + 0.25 * 200) / (300 + 200))
```

Что делает код. Взвешенное среднее: сумма (доля $\times$ вес) делить на сумму весов. Это не $(0.10+0.25)/2$.

4.3. Отношение и пропорция

Отношение $a : b$ есть частное a/b . Его сокращают как дробь. Обратное отношение — $b : a$. Отношение трёх и более чисел сокращают только на общий делитель всех членов: $6 : 9 : 10$ на 3 сократить нельзя, потому что 10 на 3 не делится.

Деление величины S в отношении $p : q : r$ режет её на $p + q + r$ равных условных частей:

$$\frac{S}{p+q+r} \cdot p, \quad \frac{S}{p+q+r} \cdot q, \quad \frac{S}{p+q+r} \cdot r.$$

Это единственная формула раздела, которая в данных встречается каждый раз, когда режут выборку, бюджет или вес класса.

Пропорция — верное равенство двух отношений, $\frac{a}{b} = \frac{c}{d}$.

Свойство. Основное свойство пропорции. Произведение крайних равно произведению средних: $ad = bc$. По этому равенству проверяют, пропорция ли перед нами, и находят неизвестный член. Неизвестный член получают так: берут известную диагональ целиком и делят на оставшееся число. Прямая пропорциональность сохраняет отношение: величины меняются в одно и то же число раз. Обратная сохраняет произведение: во сколько раз выросла одна, во столько же упала другая. На таблице прямая — «все значения столбца умножили на одну константу, отношения внутри столбца не изменились». Обратная — частота события и длина окна при фиксированном числе событий.

[задача]

Что просят. Сложить части отношения, найти размер одной части и умножить её на каждый член. Получатся три куска таблицы.

Разбейте 5000 объектов в отношении $8 : 1 : 1$.

[разбор] Идём по шагам. Частей $8 + 1 + 1 = 10$, одна часть $5000 : 10 = 500$. Куски 4000, 500, 500. Это тот же приём, что `split 80/10/10`.

[код]

```
import numpy as np
parts = np.array([8, 1, 1])
```

```
print(5000 * parts / parts.sum())
```

Что делает код. `pr.array` из двух частей склеивает выборку. `pr.full` заполняет кусок одной меткой. `.mean()` по склеенному столбцу — доля класса в объединении.

4.4. [в данных] Зачем это нужно

Uplift²⁰, CTR²¹, конверсия, доля оттока записывают процентом. CTR и конверсия живут на разных знаменателях: клики к показам и покупки к кликам. Их нельзя перемножать как пункты. Смешать пункты и относительный рост в одном абзаце отчёта — типичная ошибка.

Разбиение `train/validation/test`²² вида 70/15/15 есть отношение 14 : 3 : 3; конкретный расчёт — упражнение 4.4. Стратификация²³ держит то же отношение внутри класса: если положительных 8%, в тесте их тоже должно быть около 8%, иначе оценка метрики смещается.

Взвешивание редкого класса по обратной частоте — снова процент: класс с долей 5% получает вес $1/0,05 = 20$, если базу берут от единицы. Скидка и наценка — множители $1 \pm p/100$; если модель предсказывает цену после скидки, витринную цену восстанавливают делением на 0,8, а не вычитанием двадцати.

[задача]

Что просят. Посчитать две разные доли: клики к показам и покупки к кликам. Знаменатели у них разные.

Показы 8000, клики 240, покупки 36. Найдите CTR и конверсию из клика в покупку.

[разбор] Идём по шагам. $CTR = 240/8000 = 0,03 = 3\%$. Конверсия $36/240 = 0,15 = 15\%$. Это две разные доли: знаменатели разные, перемножать проценты как пункты нельзя.

[код]

```
print(240 / 8000, 36 / 240)
```

Что делает код. Обычное деление двух чисел. Первое — доля кликов среди показов, второе — доля покупок среди кликов.

4.5. Три типовые задачи на процент

Процент — та же доля, только умноженная на сто. Поэтому задач на процент ровно три, и они отличаются тем, что известно.

Первая: какую долю составляет a от b :

$$p = \frac{a}{b} \cdot 100\%.$$

Вторая: $p\%$ от числа b равны $\frac{p}{100} \cdot b$. Третья: если $p\%$ числа равны a , само число есть $a : \frac{p}{100}$.

²⁰ Прирост метрики относительно контроля: не сама конверсия, а насколько она стала выше.

²¹ Click-through rate: доля кликов среди показов.

²² Три куска таблицы: на одном модель учит, на втором подбирают настройки, на третьем один раз проверяют. Третий кусок нельзя трогать до конца.

²³ Нарезка выборки так, чтобы доля каждого класса в кусках совпадала с долей в целой таблице.

Удобные ходы, чтобы не таскать каждый раз 100: 1% — деление на сто; 10% — на десять; 50% — пополам; 25% — четверть; 5% — половина от десяти.

Обратно: известен 1% — умножить на сто; известны 10% — на десять; 50% — удвоить.

Примеры одной тройки. 15% от 80 есть 12. Число 12 составляет от 60 ровно 20%. Если 18 это 30% числа, число равно 60.

Увеличение на $x\%$ есть множитель $1 + x/100$, уменьшение — $1 - x/100$. Если известен уже новый результат, старый получают делением на тот же множитель: после скидки 20% цена 480, было $480/0,8 = 600$.

[в данных] Зачем это нужно

Ассигасу 47 из 50 — первая задача: доля верных. «Модель покрывает 15% базы» — вторая. «Положительных в тесте 36, и это 12% теста» — третья: длина теста 300. Путать вторую и третью — получить витринную цену вместо цены со скидкой.

[задача]

Что просят. Решить все три типа на разных числах: процент от числа, долю в процентах и целое по части.

Найдите 15% от 80. Какой процент составляет 12 от 60? Число, 30% которого равны 18.

[разбор] Идём по шагам. $0,15 \cdot 80 = 12$. $12/60 = 0,2 = 20\%$. $18/0,3 = 60$.

[код]

```
print(0.15 * 80)
print(12 / 60 * 100)
print(18 / 0.30)
```

Что делает код. Три обычных умножения и деления. Никакой отдельной «функции процента» нет: процент — множитель $p/100$.

4.6. Сухое вещество и кредит

Концентрация — снова доля:

$$c = \frac{m_{\text{вещества}}}{m_{\text{смеси}}}.$$

Вода уходит, сухое вещество нет. Масса смеси падает, доля растёт. Было 5 кг раствора с 20% вещества. Выпарили до 25%. Сухого было и осталось 1 кг, новая масса смеси $1/0,25 = 4$ кг.

Кредит с равным платежом (аннуитет) — геометрическая прогрессия: каждая выплата гасит процент на остаток и кусок тела долга. Формулу целиком здесь не разворачиваем; важно, что множитель снова $(1 + r)^n$, как у сложного процента.

[задача]

Что просят. Сначала найти неизменную массу вещества, затем новую массу смеси по новой концентрации.

Было 8 кг раствора с 10% соли. Выпарили воду до 16%. Какая масса смеси стала?

[разбор] Идём по шагам. Соли $0,10 \cdot 8 = 0,8$ кг, она не уходит. Новая масса $0,8/0,16 = 5$ кг.

[код]

```
salt = 0.10 * 8
print(salt, salt / 0.16)
```

Что делает код. Сначала считают неизменную часть, потом делят её на новую долю. Это третья типовая задача на процент: число по проценту.

Задачи — пункты 4.1–4.9 в §12.

5. Многочлены, уравнения, неравенства

Буква в формуле — это место, куда потом подставят столбец. Одночлен — коэффициент, умноженный на переменные в натуральных степенях, вроде $3x^2$. Многочлен — конечная сумма таких кусков, вроде $3x^2 - x + 1$. После приведения подобных его пишут

$$a_n x^n + \dots + a_1 x + a_0, \quad a_n \neq 0;$$

n называют степенью. Раскрытие скобок есть дистрибутивность из первого раздела.

Разложение — обратный ход: общий множитель, группировка, формулы сокращённого умножения, корни квадратного трёхчлена.

$$\begin{aligned} (a \pm b)^2 &= a^2 \pm 2ab + b^2, \\ (a \pm b)^3 &= a^3 \pm 3a^2b + 3ab^2 \pm b^3, \\ a^2 - b^2 &= (a - b)(a + b), \\ a^3 \pm b^3 &= (a \pm b)(a^2 \mp ab + b^2). \end{aligned}$$

Сумму квадратов $a^2 + b^2$ на линейные действительные множители не раскладывают. Группировка: $x^3 - 8x^2 + x - 8 = (x - 8)(x^2 + 1)$.

5.1. Линейные и квадратные уравнения

Линейное $ax + b = 0$ имеет корень $x = -b/a$ при $a \neq 0$. При $a = b = 0$ корнем служит любое число. При $a = 0$, $b \neq 0$ корней нет.

Квадратное $ax^2 + bx + c = 0$, $a \neq 0$, управляется дискриминантом $D = b^2 - 4ac$. При $D > 0$ два различных корня $\frac{-b \pm \sqrt{D}}{2a}$, при $D = 0$ один корень кратности два, при $D < 0$ вещественных корней нет. Неполные случаи не требуют D : $ax^2 = 0$ даёт только $x = 0$; $ax^2 + bx = 0$ выносит x и даёт 0 и $-b/a$; $ax^2 + c = 0$ сводится к $x = \pm \sqrt{-c/a}$ при $-c/a \geq 0$.

Свойство. Теорема Виета. Для $ax^2 + bx + c = 0$ сумма корней равна $-b/a$, произведение равно c/a . Отсюда разложение

$$ax^2 + bx + c = a(x - x_1)(x - x_2).$$

Проверка разложения — сложить и перемножить скобки и сравнить с коэффициентами.

Система двух линейных уравнений — две прямые на плоскости. Они пересекаются в точке, параллельны или совпадают. В данных первый случай — одно решение фильтра, второй — противоречивые условия, третий — дублирующее ограничение.

Дробно-рациональное уравнение сводят к многочленному, отдельно выписывая нули знаменателя: они не корни.

[задача]

Что просят. Четыре отдельных действия: раскрыть линейное уравнение, решить квадратное через дискриминант, сложить систему и разложить трёхчлен по Виете.

Решите $2(x - 3) + 5 = x + 1$, $x^2 - 3x - 10 = 0$ и систему $x + y = 10$, $x - y = 2$. Разложите $x^2 - 5x + 6$.

[разбор] Идём по шагам. Линейное: $2x - 6 + 5 = x + 1$, $2x - 1 = x + 1$, $x = 2$. Квадратное: $D = 9 + 40 = 49$, корни $\frac{3 \pm 7}{2}$, то есть 5 и -2 . Система: сложение даёт $2x = 12$, $x = 6$, $y = 4$. По Виете сумма 5, произведение 6, поэтому $x^2 - 5x + 6 = (x - 2)(x - 3)$.

[код]

```
from sympy import symbols, Eq, solve, factor
import numpy as np
x, y = symbols("x y")
print(solve(Eq(2*(x-3)+5, x+1), x))
print(solve(Eq(x**2 - 3*x - 10, 0), x))
print(factor(x**2 - 5*x + 6))
print(np.roots([1, -3, -10]))
print(solve([Eq(x+y, 10), Eq(x-y, 2)], [x, y]))
```

Что делает код. symbols объявляет буквы. Eq записывает уравнение. solve ищет корни. factor раскладывает многочлен на скобки.

5.2. Неравенства и метод интервалов

Неравенство в отличие от уравнения даёт промежуток, а не набор точек. Знаки $>$ и $<$ — строгие, $\geq$ и $\leq$ — нестрогие. Решением может быть промежуток, объединение промежутков, отдельные точки или пустое множество. Образец записи: $x \in (0; 0,8] \cup \{2\} \cup [4, 3; +\infty)$.

Промежутки различают по концам. Пустой кружок на прямой — точка не входит, закрашенный — входит. Бесконечность всегда круглая: до неё нельзя «дойти».

Обозначение	Название	Модель	Концы
$(a; +\infty)$	открытый луч	$x > a$	a выколота
$[a; +\infty)$	луч	$x \geq a$	a закрашена
$(-\infty; b)$	открытый луч	$x < b$	b выколота
$(-\infty; b]$	луч	$x \leq b$	b закрашена
$(a; b)$	интервал	$a < x < b$	обе выколоты
$[a; b]$	отрезок	$a \leq x \leq b$	обе закрашены
$[a; b)$	полуинтервал	$a \leq x < b$	левая закрашена
$(a; b]$	полуинтервал	$a < x \leq b$	правая закрашена

Допустимые преобразования — не лозунг «прибавили и умножили», а короткий список запретов. К обеим частям можно прибавить одно и то же число: $a < b \iff a + c < b + c$. Вычитать

одно неравенство из другого нельзя: направления могут не совпасть. Переворот меняет знак: $a \geq b \iff b \leq a$. Однонаправленные неравенства складывают почленно. Умножение (деление) на положительное знак сохраняет, на отрицательное — меняет. Делить одно неравенство на другое нельзя. Почленное умножение допустимо, только когда все части неотрицательны; произведение строгого и нестрогого даёт строгое. Возведение в натуральную степень — при неотрицательных частях. Переход к обратным переворачивает знак и требует положительных частей:

$$a > b > 0 \iff \frac{1}{a} < \frac{1}{b}.$$

Отсюда позже получится, что меньшая вероятность даёт больший минус-логарифм.

Линейное неравенство $ax + b \vee 0$ сводят к промежутку делением на коэффициент при x . Если коэффициент отрицательный, знак меняется. Система линейных неравенств — пересечение промежутков. На прямой их рисуют «крышами» разной высоты: в ответ идёт участок, над которым нависли все крыши. Все знаки «больше» — правее самого правого порога; все знаки «меньше» — левее самого левого. Это ровно запись фильтра `age >= 18 and age < 40`.

Модуль:

$$|x| < a \iff -a < x < a, \quad |x| > a \iff x < -a \text{ или } x > a$$

при $a > 0$.

Метод интервалов работает с произведением множителей $(x - x_i)^{k_i}$. Корни наносят на прямую. Кратность корня — сколько множителей обращаются в ноль при подстановке этого числа.

Свойство. Смена знака. При переходе через корень нечётной кратности знак меняется, чётной — нет. Чётная кратность — это касание оси: выражение обнуляется и возвращается на ту же сторону. Нули знаменателя всегда выкалывают: в них выражения нет. При нестрогом знаке ноль числителя входит; если вокруг точки чётной кратности знак не тот, точку всё равно записывают отдельно в фигурных скобках.

Так,

$$\frac{x}{x-1} \geq 0$$

даёт $(-\infty; 0] \cup (1; +\infty)$: ноль числителя входит, полюс не входит.

Дробно-рациональное $\frac{A}{B} \vee 0$ решают тем же методом после переноса всего налево. Умножать неравенство на знаменатель с переменной нельзя: неизвестно, положителен он или нет, и на его нулях выражения нет. Кратность суммируется по числителю и знаменателю. Разные скобки могут давать один корень — левую часть доводят до линейных $(x - x_n)$.

[задача]

Что просят. Свести линейное неравенство к промежутку, квадратное — к отрезку между корнями, затем применить порог к списку чеков как фильтр.

Решите $3(x-1) > x+5$ и $x(x-4) \leq 0$. Из чеков 200, 1500, 800, 1200 оставьте те, что не меньше 1000.

[разбор] Идём по шагам. Первое: $3x - 3 > x + 5$, $2x > 8$, $x \in (4; +\infty)$. Второе: корни 0 и 4, парабола ветвями вверх, произведение неположительно на отрезке $[0; 4]$. Фильтр $x \geq 1000$ оставляет 1500 и 1200.

[код]

```
import numpy as np
from sympy import symbols, reduce_inequalities
x = symbols("x")
print(reduce_inequalities(3*(x-1) > x+5, x))
cheks = np.array([200, 1500, 800, 1200])
print(cheks[cheks >= 1000])
```

Что делает код. `np.array > t` строит маску: массив из True/False. `x[x >= 1000]` оставляет только прошедшие порог строки. Так в таблице работает фильтр.

[задача]

Что просят. Нанести нули числителя и знаменателя на прямую, учесть кратность и выколоть полюс, выбрать промежутки, где выражение неположительно.

$$\text{Решите } \frac{(x-1)^2}{x+4} \leq 0.$$

[разбор] Идём по шагам. Числитель ноль при $x = 1$, кратность 2, точка закрашена. Знаменатель ноль при $x = -4$, точка всегда выколота. Чётная кратность знак не меняет. Знаки: минус на $(-\infty; -4)$, плюс на $(-4; 1)$, плюс на $(1; +\infty)$. Нужны неположительные значения: $x \in (-\infty; -4) \cup \{1\}$. Точку 1 не проглатывает соседний плюс: в ней само выражение равно нулю, и нестрогий знак её берёт.

[код]

```
import numpy as np
vals = np.array([-5.0, -4.1, -3.0, 1.0, 2.0])
print(((vals - 1)**2) / (vals + 4))
```

Что делает код. Сравнение $(x-1)**2 * (x+4) \leq 0$ в каждой точке сетки не заменяет метод интервалов: сетка может промахнуться мимо корня. Это только проверка знаков.

Пробные точки подтверждают знаки. Библиотека не отменяет метод интервалов: `sympy` удобен на линейном, на дробно-рациональном надёжнее массив проб.

5.3. [в данных] Зачем это нужно

Линейное неравенство — фильтр столбца: `df[df.amount >= 1000]`. Система — несколько фильтров сразу, пересечение булевых масок. Знак после умножения на отрицательное — перевернут условия, когда признак берут с минусом: убывающая связь, штраф, отрицательный вес.

Метод интервалов отвечает на вопрос, где выражение-признак положительно. Для $\log x$ область $x > 0$, для $\sqrt{x}$ — $x \geq 0$: прежде чем считать столбец, выписывают, где выражение существует. Для скорингового балла $s(x) - t$ — область, где модель говорит «да». Дробно-рациональный признак вида «отношение двух столбцов» ломается на нуле знаменателя ровно так, как полюс в методе интервалов: строка уходит в неопределённость, её выкалывают или чинят отдельно.

Квадратичный функционал $\sum (y_i - wx_i)^2$ есть многочлен второй степени по весу w . Его минимум ищут позже анализом, но сам объект уже здесь. Разложение многочлена сокращает алгебраический признак до произведения скобок и показывает, где он меняет знак.

5.4. Равносильные преобразования и системы

Уравнение — равенство, в котором есть неизвестная. Решить — найти все значения, которые равенство делают верным, и не взять лишних.

Преобразование равносильно, если не теряет корней и не добавляет посторонних. Можно прибавить одно и то же число к обеим частям, умножить обе части на одно и то же *ненулевое* число. Умножение на ноль или на выражение, которое умеет быть нулём, равносильность ломает. В дробном уравнении отдельно пишут ограничение: знаменатель не ноль. Корень, который знаменатель обнуляет, отбрасывают.

Текстовая задача на уравнение переводит слова в букву: «на 3 больше» есть $x + 3$, «в два раза» есть $2x$. Сначала величина, потом уравнение, потом проверка в условии, не только в формуле.

Диофантово уравнение ищет целые решения. На этапе 1 достаточно помнить: не всякое линейное уравнение с целыми коэффициентами имеет целый корень.

Систему двух линейных уравнений решают подстановкой или сложением. Подстановка: из одного уравнения выражают букву и подставляют в другое. Сложение: уравнения умножают на такие числа, чтобы одна буква при сложении уничтожилась.

Пример сложения.

$$\begin{cases} 2x + y = 7, \\ x - y = 2. \end{cases}$$

Складывают как есть: $3x = 9$, $x = 3$, тогда $y = 1$. Проверка: $2 \cdot 3 + 1 = 7$, $3 - 1 = 2$.

У системы двух линейных на плоскости три картины: одна точка (прямые пересеклись), пусто (параллельны), вся прямая (это одно и то же уравнение дважды).

[в данных] Зачем это нужно

Два ограничения на признаки — система неравенств или уравнений на допустимую область. Если при очистке таблицы делят обе части связи на столбец, который умеет быть нулём, получают посторонние строки. Это та же потеря равносильности.

[задача]

Что просят. Решить систему сложением и проверить оба уравнения подстановкой.

Решите $2x + y = 7$, $x - y = 2$.

[разбор] *Идём по шагам.* Сумма $3x = 9$, $x = 3$, $y = 7 - 6 = 1$. Проверка выше уже сошлась.

[код]

```
from sympy import symbols, Eq, solve
x, y = symbols('x y')
print(solve([Eq(2*x + y, 7), Eq(x - y, 2)], [x, y]))
```

Что делает код. `symbols` объявляет две буквы. `Eq` — уравнение, не обычное `=`. `solve` по списку уравнений и списку букв возвращает словарь корней.

5.5. Промежутки и система неравенств

Неравенство отмечает на прямой не точку, а кусок. Куски записывают так:

$$\begin{aligned}x &> a && \text{луч } (a; +\infty), \\x &\geq a && \text{луч } [a; +\infty), \\a < x < b && \text{интервал } (a; b), \\a \leq x \leq b && \text{отрезок } [a; b].\end{aligned}$$

Круглая скобка выкалывает точку, квадратная — закрашивает.

Допустимые преобразования те же, что у уравнений, плюс одно: умножение на отрицательное число разворачивает знак.

Система неравенств есть пересечение кусков. Решают каждое, затем оставляют общую часть. $x > 1$ и $x \leq 4$ дают $x \in (1; 4]$. В таблице это фильтр «признак строго больше порога и не больше второго порога». Строка должна пройти оба.

[задача]

Что просят. Решить два неравенства по отдельности и взять пересечение — один промежуток.

Решите систему $x \geq -1, 2x < 6$.

[разбор] Идём по шагам. Первое: $x \in [-1; +\infty)$. Второе: $x < 3$, то есть $x \in (-\infty; 3)$. Пересечение $[-1; 3)$.

[код]

```
import numpy as np
x = np.array([-2., -1, 0, 2, 3, 4])
print(x[(x >= -1) & (x < 3)])
```

Что делает код. & — логическое «и» для масок. Скобки вокруг сравнений обязательны: иначе приоритет операций соберёт не ту маску.

Задачи — пункты 5.1–5.12 в §12.

6. Координаты и функции

Прямая уже введена в разделе 1: ноль, направление, порядок. Промежуток на ней — множество решений простейшего неравенства. На плоскости точка есть пара (x, y) . Расстояние

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

есть теорема Пифагора и одновременно евклидова норма разности двух векторов из последнего раздела.

6.1. Функция

Функция f сопоставляет каждому допустимому x ровно одно число $f(x)$. Область определения — те входы, на которых правило имеет смысл. Линейная $kx + b$ имеет постоянный наклон k .

Нормализация

$$\tilde{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

переводит отрезок значений в $[0, 1]$ и сохраняет отношение деления: середина переходит в середину. Квадратичная $ax^2 + bx + c$ — парабола с вершиной $x = -b/(2a)$. Модуль склеивает две полупрямые. Гипербола k/x не определена в нуле.

[задача]

Что просят. Подставить пять точек в линейную формулу. Затем найти, какую долю отрезок от 10 до 50 составляет число 30, — это и есть образ при сжатии в $[0; 1]$.

Постройте таблицу $y = 1 - 0,5x$ в точках $-2, -1, 0, 1, 2$. Куда перейдёт 30 при линейном сжатии $[10; 50]$ в $[0; 1]$?

[разбор] Идём по шагам. Значения 2; 1,5; 1; 0,5; 0. Образ 30: $\frac{30 - 10}{50 - 10} = \frac{1}{2}$.

[код]

```
import numpy as np
x = np.array([-2., -1, 0, 1, 2])
print(1 - 0.5*x)
print((30 - 10) / (50 - 10))
```

Что делает код. `np.array` из точек. Арифметика с массивом применяется к каждой координате сразу: так считают столбец признака. Деление — линейное сжатие отрезка в $[0; 1]$.

6.2. [в данных] Зачем это нужно

Строка с двумя числовыми полями — точка плоскости. Облако строк — график выборки. Если облако тянется вдоль прямой, модель $y \approx kx + b$ осмысленна как первое приближение; k потом станет коэффициентом регрессии. Расстояние между строками — мера близости для ближайших соседей. Нормализация признака — линейная функция из этого раздела. Порог $s(x) \geq t$ вырезает на прямой оценки луч.

Расстояние до $(5, 12)$ и сжатие другого отрезка — упражнения 6.2 и 6.3.

Задачи — пункты 6.1–6.5.

7. Последовательности

Последовательность — функция натурального аргумента. Арифметическая задаётся постоянной разностью:

$$a_n = a_1 + (n - 1)d, \quad S_n = \frac{n}{2}(a_1 + a_n).$$

Геометрическая — постоянным отношением:

$$b_n = b_1 q^{n-1}.$$

Сложный процент — геометрическая прогрессия с $q = 1 + r$. Простой — арифметическая: каждый период прибавляют одну и ту же сумму.

Итерация $w_{t+1} = w_t - \eta g_t$ тоже последовательность. При постоянном шаге и постоянном градиенте она была бы арифметической. Экспоненциальное скользящее среднее²⁴

$$s_t = \alpha x_t + (1 - \alpha)s_{t-1}$$

есть линейный рекуррентный фильтр. Память бесконечна, но экспоненциально забывчива: после серии нулей оценка тает со знаменателем $1 - \alpha$.

[задача]

Что просят. По формуле n -го члена и суммы собрать десятый член и сумму арифметики, шестой член геометрии, затем три шага экспоненциального фильтра.

Для арифметики $a_1 = 5$, $d = 3$ найдите a_{10} и S_{10} . Для геометрии $b_1 = 2$, $q = 3$ найдите b_6 . Прогоните фильтр $\alpha = 1/2$, $s_0 = 0$ по ряду 10, 0, 0.

[разбор] Идём по шагам. $a_{10} = 5 + 9 \cdot 3 = 32$, $S_{10} = \frac{10}{2}(5 + 32) = 185$. $b_6 = 2 \cdot 3^5 = 486$. Фильтр: 5; затем 2,5; затем 1,25. После серии нулей оценка тает вдвое на каждом шаге.

[код]

```
print(5 + 9*3, 10/2 * (5+32))
print(2 * 3**5)
s, a = 0.0, 0.5
for xt in (10, 0, 0):
    s = a*xt + (1-a)*s
    print(s)
```

Что делает код. Снова обычные $+$ и $*$. Формула n -го члена арифметики и сумма геометрической — это те же четыре действия.

7.1. [в данных] Зачем это нужно

Временной ряд — последовательность. Скользящее среднее сглаживает шум. Learning rate decay по расписанию — снова последовательность. Капитализация и рост метрики по неделям считаются теми же формулами, что вклад в банке. Сложный процент $50\,000 \cdot 1,08^3$ уже разобран в разделе про проценты — здесь его не повторяем.

Капитализацию $20\,000 \cdot 1,01^6$ и фильтр с другим α оставляем упражнениям 7.3 и 7.5.

Задачи — пункты 7.1–7.5.

8. Множества и комбинаторика

Множество задаётся списком или свойством. Повторы и порядок не считаются. Объединение — всё, что лежит хотя бы в одном, пересечение — то, что лежит в обоих, разность — то, что лежит в первом и не лежит во втором. Чтобы не посчитать общие элементы дважды,

$$|A \cup B| = |A| + |B| - |A \cap B|.$$

²⁴Фильтр: новая оценка есть смесь текущего наблюдения и предыдущей оценки. Старые значения забываются, но не обнуляются сразу.

8.1. Размещения и сочетания

Перестановки n различных объектов считаются факториалом: первое место n способами, второе $n - 1$, и так далее. Упорядоченная выборка k из n без повторений — размещение

$$A_n^k = \frac{n!}{(n-k)!}.$$

Если порядок не важен, каждую группу посчитали $k!$ раз, поэтому

$$C_n^k = \frac{n!}{k!(n-k)!} = C_n^{n-k}.$$

Рекурсия Паскаля $C_n^k = C_{n-1}^{k-1} + C_{n-1}^k$ разбирает фиксированный элемент: он либо входит в подмножество, либо нет. Частный случай — число неупорядоченных пар: $C_n^2 = n(n-1)/2$.

[задача]

Что просят. Посчитать одно сочетание из восьми и пару размещение/сочетание из четырёх. Сравнить и объяснить разницу порядком.

Найдите C_8^3 , A_4^2 и C_4^2 . Почему размещений больше, чем сочетаний?

[разбор] Идём по шагам. $C_8^3 = \frac{8 \cdot 7 \cdot 6}{3!} = 56$. $A_4^2 = 4 \cdot 3 = 12$, $C_4^2 = 6$: в сочетании порядок забыт, каждую пару посчитали $2!$ раз, поэтому размещений вдвое больше.

[код]

```
import math
print(math.comb(8, 3), math.perm(4, 2), math.comb(4, 2))
```

Что делает код. `math.comb(n, k)` — число сочетаний C_n^k . `math.perm` — число размещений. Обе считают факториалами, но не печатают огромный $n!$.

8.2. [в данных] Зачем это нужно

Если A — строки с пропуском в столбце X , B — в столбце Y , то $|A \cup B|$ есть число строк, где дырка хотя бы в одном из двух столбцов. Пересечение идентификаторов `train` и `test` должно быть пустым. Если $A \cap B \neq \emptyset$, часть объектов видели и при обучении, и при оценке, метрика завышена.

C_n^k считает число подмножеств признаков фиксированного размера при полном переборе. Та же формула даёт число pairwise-сравнений и число one-vs-one классификаторов. Сочетание вернётся в схеме Бернулли: число способов расставить k успехов по n попыткам.

[задача]

Что просят. Найти общие идентификаторы двух множеств и объяснить, почему пересечение `train` и `test` портит оценку.

`Train-id {1, 2, 3, 4, 5}`, `test-id {5, 6, 7}`. Найдите пересечение и скажите, почему это плохо для оценки модели.

[разбор] Идём по шагам. Пересечение $\{5\}$ — один объект в обеих частях. Формула включений здесь не нужна: достаточно операции пересечения. Метрика на тесте завышена, потому что модель уже видела этот объект.

[код]

```
import numpy as np
print(np.intersect1d(np.array([1, 2, 3, 4, 5]), np.array([5, 6, 7])))
```

Что делает код. `np.union1d` — объединение без повторов. `np.intersect1d` — пересечение. Это $|A \cup B|$ и $|A \cap B|$ на конечных наборах.

Кардинальности $|A| = 12$, $|B| = 9$, $|A \cup B| = 16$ оставляем упражнению 8.1: в теории достаточно формулы и одного пересечения идентификаторов.

Задачи — пункты 8.1–8.5.

9. Выборка

Пусть даны числа $x_1, \dots, x_n$. Среднее

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

минимизирует сумму квадратов уклонений. Медиана — центр упорядоченного ряда: при нечётном n средний член, при чётном — полусумма двух центральных; она минимизирует сумму модулей. Размах $\max x_i - \min x_i$ смотрит только на края и ломается одним выбросом.

Несмещённая выборочная дисперсия

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

делится на $n - 1$, чтобы в среднем совпадать с дисперсией порождающего распределения. Корень s — стандартное отклонение. Стандартизация

$$z_i = \frac{x_i - \bar{x}}{s}$$

центрирует столбец и приводит разброс к единице. Сумма всех z_i равна нулю.

[задача]

Что просят. По пяти числам собрать четыре описательные величины: среднее, медиану, размах и исправленную дисперсию.

Для ряда 3, 5, 5, 8, 11 найдите среднее, медиану, размах и s^2 .

[разбор] Идём по шагам. Сумма 32, среднее 6,4, медиана 5, размах 8. Квадраты отклонений дают 39,2, $s^2 = 39,2/4 = 9,8$. Взвешенное среднее двух групп уже разобрано на дробях; стандартизацию этого ряда оставляем упражнению 9.4.

[код]


```
import numpy as np
x = np.array([3., 5, 5, 8, 11])
print(x.mean(), np.median(x), x.ptp(), x.var(ddof=1))
```

Что делает код. `x.mean()` — среднее. `np.median` — медиана. `x.ptp()` — размах (peak-to-peak). `x.var(ddof=1)` — исправленная дисперсия: деление на $n - 1$, не на n .

9.1. [в данных] Зачем это нужно

Столбец таблицы — выборка. Среднее и медиана отвечают на разные вопросы: «центр масс» и «типичный объект». Чек 100 среди чеков около 12 утаскивает среднее и почти не двигает медиану. MAE естественно связан с медианой, MSE — со средним: выбор функции потерь есть выбор центра. Стандартизация ставит признаки с разными единицами в одну шкалу до линейной модели или ближайших соседей. Делитель $n - 1$ в NumPy задают флагом `ddof=1`; без него получают другую нормализацию. Стандартизацию ряда и проверку $\sum z_i = 0$ считает упражнение 9.4.

Задачи — пункты 9.1–9.5.

10. Вероятность

Случайный опыт задаёт множество исходов Ω . Событие — подмножество. Если исходы равно-возможны и конечны,

$$P(A) = \frac{|A|}{|\Omega|}.$$

Во всех случаях $0 \leq P(A) \leq 1$, $P(\Omega) = 1$, $P(\emptyset) = 0$ и

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

При непересекающихся событиях последнее слагаемое исчезает.

10.1. Условие, независимость, Байес

Если $P(A) > 0$,

$$P(B | A) = \frac{P(A \cap B)}{P(A)}.$$

Это новый мешок: сначала оставили только исходы из A , потом среди них смотрят долю B . Независимость означает, что условие ничего не меняет: $P(A \cap B) = P(A)P(B)$.

Формула Байеса есть переворот определения:

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}.$$

Знаменатель раскладывают полной вероятностью, если есть разбиение гипотез.

Схема Бернулли: n независимых опытов с одной вероятностью успеха p .

$$P(X = k) = C_n^k p^k (1 - p)^{n-k}.$$

Сочетание здесь потому, что k успехов расставляют по n позициям C_n^k способами.

[задача]

Что просят. Три разных счёта: доля исходов на кости, формулы независимых событий, биномиальная вероятность пяти успехов из десяти.

Вероятность чётного на кости. Независимые A, B с $P(A) = 0,6$, $P(B) = 0,3$: найдите пересечение и объединение. Вероятность ровно пяти орлов в десяти бросках.

[разбор] Идём по шагам. Чётных граней три из шести, $P = 1/2$. Пересечение 0,18, объединение $0,6 + 0,3 - 0,18 = 0,72$. $C_{10}^5/2^{10} = 252/1024 = 63/256$.

[код]

```
import math
print(3/6)
print(0.6*0.3, 0.6+0.3-0.18)
print(math.comb(10, 5) / 2**10)
```

Что делает код. `math.comb` снова считает C_{10}^5 . Деление на 2^{10} — классическая вероятность пяти орлов.

10.2. [в данных] Зачем это нужно

Классификатор, который оценивает $P(y = 1 | x)$, работает с объектом этого раздела. Precision и recall из разделов 1–2 здесь читаются как две разные условные вероятности: $P(\text{истина} | \text{модель сказала «да»})$ и наоборот. Байес объясняет редкий класс: даже хороший тест на фоне большой массы здоровых даёт скромную апостериорную вероятность, потому что знаменатель раздувают ложные тревоги.

[задача]

Что просят. Сначала полную вероятность теста, затем по Байесу вероятность болезни при положительном тесте.

Дано: $P(D) = 0,01$, $P(T | D) = 0,99$, $P(T | \neg D) = 0,05$. Найдите $P(T)$ и $P(D | T)$.

[разбор] Идём по шагам. Полная вероятность $P(T) = 0,99 \cdot 0,01 + 0,05 \cdot 0,99 = 0,0594$. Апостериорная $P(D | T) = 0,0099/0,0594 \approx 0,167$. Даже хороший тест на редком классе даёт скромную вероятность: знаменатель раздувают ложные тревоги.

[код]

```
p_d, p_td, p_tnd = 0.01, 0.99, 0.05
p_t = p_td*p_d + p_tnd*(1-p_d)
print(p_t, p_td*p_d / p_t)
```

Что делает код. Три числа — данные задачи. Полная вероятность собирается как сумма по веткам. Деление — формула Байеса.

Задачи — пункты 10.1–10.5.

11. Векторы

Упорядоченную пару складывают и умножают на число покомпонентно. Эти две операции превращают $\mathbb{R}^2$ в векторное пространство: есть ноль и противоположный, а сложение и умножение на

скаляр подчиняются тем же законам, что операции в $\mathbb{Z}$. Длина

$$\|\vec{v}\| = \sqrt{v_1^2 + v_2^2}$$

совпадает с расстоянием от начала координат. Скалярное произведение

$$\vec{u} \cdot \vec{v} = u_1 v_1 + u_2 v_2 = \|\vec{u}\| \|\vec{v}\| \cos \varphi$$

задаёт угол и проекцию. Ортогональность есть обращение произведения в нуль.

[задача]

Что просят. Сложить векторы по координатам, растянуть первый и вычесть второй, затем сложить произведения координат. Дальше — длина, орт и условие прямого угла.

Для $\vec{a} = (1, 2)$, $\vec{b} = (2, 1)$ найдите сумму, $3\vec{a} - \vec{b}$ и скалярное произведение. Длину и единичный вектор для $(3, 4)$. При каком c векторы $(1, c)$ и $(2, -1)$ ортогональны?

[разбор] Идём по шагам. Сумма $(3, 3)$, $3\vec{a} - \vec{b} = (1, 5)$, произведение 4. Длина $\sqrt{9 + 16} = 5$, единичный $(3/5, 4/5)$. Ортогональность: $2 - c = 0$, значит $c = 2$.

[код]

```
import numpy as np
a = np.array([1.0, 2.0]); b = np.array([2.0, 1.0])
print(a+b, 3*a-b, np.dot(a, b))
u = np.array([3.0, 4.0])
print(np.linalg.norm(u), u / np.linalg.norm(u))
print(np.dot(np.array([1.0, 2.0]), np.array([2.0, -1.0])))
```

Что делает код. `np.array` задаёт векторы. Сложение и `*` растягивают по координатам. `np.dot` — скалярное произведение.

11.1. [в данных] Зачем это нужно

Строка с двумя признаками — вектор. Линейная модель предсказывает $w \cdot x + b$: это скалярное произведение весов и признаков плюс сдвиг. Косинус между мешками слов²⁵ измеряет похожесть направления и не зависит от длины документов. Центрирование выборки — вычитание вектора средних из каждой строки.

[задача]

Что просят. По каждому столбцу взять среднее и вычесть его из обеих строк. Проверить, что сумма по столбцу стала нулём.

Строки $(1, 3)$ и $(5, 7)$. Найдите вектор средних по столбцам и центрированные строки.

[разбор] Идём по шагам. Средние столбцов 3 и 5. Центрированные $(-2, -2)$ и $(2, 2)$. Сумма по каждому столбцу после центрирования равна нулю.

[код]

²⁵Представление текста: каждое слово — координата, значение — сколько раз слово встретилось, порядок слов забыт.

```
import numpy as np
X = np.array([[1.0, 3.0], [5.0, 7.0]])
print(X.mean(axis=0))
print(X - X.mean(axis=0))
```

Что делает код. `X.mean(axis=0)` — среднее по столбцам (вниз по строкам). `X - X.mean(axis=0)` вычитает это среднее из каждой строки: центрирование.

Нормировка $\vec{v}/\|\vec{v}\|$ оставляет направление и убивает масштаб. Ближайшие соседи²⁶ сравнивают длины разностей. Косинус для пары (3, 4) и (4, 3) и нормировку (6, 8) оставляем упражнениям 11.2 и 11.3. Далее появятся матрицы: таблица целиком станет набором векторов и одним объектом линейной алгебры.

Задачи — пункты 11.1–11.5.

Этим этап 1 закрывается. Следующий текст — матрицы и системы большего размера, затем многомерная вероятность, затем производная как скорость изменения и градиент как направление наискорейшего роста.

²⁶Метод, который смотрит на самые близкие уже известные объекты и переносит их ответ на новый.

12. Задачи

Нумерация $k.m$ означает задачу m раздела k . Полные решения собраны в §13 — туда стоит идти только после своей попытки. В формулировке ответа нет: сначала сами решаете, что дано и что просят. Числа здесь другие, чем в разобранных примерах теории. Приём тот же, счёт новый.

12.1. К разделу 1

- 1.1 Даны числа 0, 1, 17, -3 , 100. Нужно разложить их по двум множествам: какие из них натуральные, какие целые. Одно число может попасть в оба.
- 1.2 Дано выражение $2 + 3 \cdot 4^2 - (8 : 2)$. Нужно посчитать его строго по порядку действий и выписать промежуточные шаги.
- 1.3 Датасет из 1847 строк режут батчами по 64. Найдите число полных батчей и длину хвоста. Какая доля строк в хвосте?
- 1.4 Нужно канонически разложить 180 и по разложению ответить, делится ли оно на 12, не выполняя длинного деления.
- 1.5 Найдите НОД(96, 144) алгоритмом Евклида и НОК(96, 144).
- 1.6 Сколько чётных чисел в множестве $\{0, 1, \dots, 14\}$?
- 1.7 Вычислите $8!/6!$ без полного $8!$.
- 1.8 Индексы 0, 1, $\dots$, 23 раскладывают в шесть фолдов операцией $\bmod 6$. В какой фолд попадёт индекс 19? Сколько индексов в фолде 1?
- 1.9 Сессия длилась 72 000 миллисекунд, скорость лога 54 км/ч. Переведите длительность в секунды и скорость в м/с.
- 1.10 Вычислите $-15 + 8 - (-3)$. Сравните $(-2)^3$ и -2^3 .
- 1.11 Округлите 4,6501 до десятых и до сотых.

12.2. К разделу 2

- 2.1 Нужно сократить дробь $\frac{36}{54}$ на НОД и сравнить $\frac{3}{8}$ с 36%, переведя оба в десятичные.
- 2.2 В таблице 4000 строк, пропусков 8%. Сколько пустых строк и какова доля заполненных?
- 2.3 Переведите 0,(7) и 0,2(3) в обыкновенные дроби.
- 2.4 Найдите взвешенное среднее: пятнадцать наблюдений со средним 6 и пять со средним 2.
- 2.5 Классификатор угадал 41 объект из 50. Запишите ассигасу обыкновенной дробью и десятичной.
- 2.6 Почему сравнение $0.1 * 3 == 0.3$ в `float` может быть ложным? Как сравнить корректно?
- 2.7 Переведите $\frac{23}{6}$ в смешанное число и $4\frac{2}{5}$ в неправильную дробь.
- 2.8 Что больше: $\frac{2}{5}$ или 38%? Чему равна $\frac{4}{15} + \frac{5}{21}$?

12.3. К разделу 3

- 3.1 Упростите $\frac{(x^2)^{-5}}{x^{-3}}$ и $\frac{b^9}{b^4}$.
- 3.2 Вычислите $\log_2 32 + \log_2 2$ и $\log_5 50 - \log_5 2$.
- 3.3 Запишите 0,0034 и 72 000 в стандартном виде.
- 3.4 Сколько раз нужно умножить 500 на 1,2, чтобы превзойти 2000?
- 3.5 Для ряда 0, 9, 99, 999 вычислите $\log_{10}(1 + x_i)$ и объясните, зачем такой сдвиг в данных.

12.4. К разделу 4

- 4.1 Нужно перевести 7% в две записи: обыкновенную дробь и десятичную.
- 4.2 Скидка 15%, к оплате 680. Найдите исходную цену.
- 4.3 Ассигасу выросла с 0,72 до 0,81. Укажите рост в пунктах и относительный рост.
- 4.4 Разбейте 3600 объектов в отношении 5 : 3 : 2.
- 4.5 Число увеличили на 10% и уменьшили на 10%. Какая доля исходного осталась? Почему это не 100%?
- 4.6 Вклад 40 000 на два года под 5%. Сравните простой и сложный процент.
- 4.7 Смешали 400 строк с долей положительного класса 0,05 и 600 строк с долей 0,20. Какая доля в объединении? Почему это не 12,5%?
- 4.8 В таблице 2000 строк, положительный класс составляет 12%. Тест забирает 20% строк и сохраняет долю класса. Сколько положительных объектов попадёт в тест? Какой вес у положительного класса при взвешивании $1/p_k$?
- 4.9 Было 12 кг раствора с 15% вещества. Выпарили воду до 20%. Какая масса смеси стала?

12.5. К разделу 5

- 5.1 Дано линейное уравнение. Нужно раскрыть скобку, собрать иксы слева, числа справа и найти корень. Проверку подстановкой тоже стоит сделать.
- 5.2 Решите $x^2 - 5x - 14 = 0$.
- 5.3 Решите $2(x + 1) < x + 7$, ответ запишите промежутком.
- 5.4 Решите $x^2 - 6x \leq 0$.
- 5.5 Решите систему $2x + y = 7, x - y = 2$.
- 5.6 Из чеков 300, 1800, 900, 1100 отберите значения ≥ 1000 . Какое неравенство вы применили?
- 5.7 Решите $\frac{x-3}{x} = 0$. Выпишите ограничение.
- 5.8 Даны два неравенства сразу. Нужно взять их пересечение, записать одним промежутком и сказать, какой фильтр на столбце этим описывается.
- 5.9 Решите $(x + 2)^2(x - 5) \leq 0$. Учтите кратность.
- 5.10 Решите $\frac{x+1}{x-3} > 0$. Почему точку $x = 3$ нельзя закрасить?
- 5.11 Решите систему $x \geq 0, 3x < 6$. Запишите одним промежутком.
- 5.12 Решите неполное квадратное $x^2 - 9 = 0$ и $x^2 + 9 = 0$ в действительных числах.

12.6. К разделу 6

- 6.1 Таблица значений $y = 2 - 0,25x$ в точках $-4, -2, 0, 2, 4$.
- 6.2 Расстояния от $(0, 0)$ до $(5, 12)$ и до $(-5, -12)$.
- 6.3 Отрезок $[20; 80]$ линейно переводят в $[0; 1]$. Образ точки 50.
- 6.4 Нули и вершина $y = x^2 - 6x + 8$.
- 6.5 Решите $0,25x - 2 = 0$ и опишите, что означает порог для оценки $s(x) = 0,25x - 2$.

12.7. К разделу 7

- 7.1 Десятый член и сумма первых десяти членов арифметики $a_1 = 4, d = 5$.
- 7.2 Шестой член геометрии $b_1 = 3, q = 2$.

- 7.3 Вклад 20 000 под 12% годовых с ежемесячной капитализацией на шесть месяцев.
- 7.4 Ряд 40, 42, 44, ... На каком номере впервые будет не меньше 50?
- 7.5 Для $\alpha = 1/3$, $s_0 = 0$, ряд 12, 0, 0 найдите три значения фильтра и объясните затухание.

12.8. К разделу 8

- 8.1 $|A| = 12$, $|B| = 9$, $|A \cup B| = 16$. Найдите $|A \cap B|$. Дайте чтение в терминах пропусков двух столбцов.
- 8.2 Сколькими способами выбрать два фолда из пяти?
- 8.3 Вычислите A_5^2 и C_5^2 и объясните, чем они отличаются.
- 8.4 Train-id {2, 4, 6, 8}, test-id {8, 10, 12}. Есть ли утечка?
- 8.5 Вычислите C_{12}^2 и скажите, что считает это число среди двенадцати объектов.

12.9. К разделу 9

- 9.1 Для 2, 4, 4, 7, 13 найдите среднее, медиану, размах и s^2 с делителем $n - 1$.
- 9.2 Пять наблюдений со средним 8 и пятнадцать со средним 4. Общее среднее.
- 9.3 К ряду 10, 12, 11, 13 добавили 100. Новые среднее и медиана. Какую величину взять как «типичный чек»?
- 9.4 Стандартизируйте (2, 4, 6) с делителем $n - 1$. Чему равна сумма z_i ?
- 9.5 Приведите пять чисел, у которых среднее совпадает с медианой, и пять, у которых они различны.

12.10. К разделу 10

- 10.1 В урне три синих и пять красных. Вероятность синего при первом извлечении и при втором, если первый синий не вернули.
- 10.2 $P(A) = 0,4$, $P(B) = 0,5$, независимость. Найдите пересечение и объединение.
- 10.3 $P(D) = 0,02$, $P(T | D) = 0,95$, $P(T | \neg D) = 0,10$. Найдите $P(D | T)$ по шагам.
- 10.4 Восемь бросков монеты. Вероятность ровно трёх орлов.
- 10.5 Модель сказала «да» 40 раз и угадала 30; истинных «да» было 50. Найдите precision и recall и напишите, чем они различаются.

12.11. К разделу 11

- 11.1 Для $\vec{a} = (3, 1)$, $\vec{b} = (1, 4)$ найдите сумму, $2\vec{a} - \vec{b}$ и скалярное произведение.
- 11.2 Косинус угла между (1, 0) и (1, 1).
- 11.3 Нормируйте (6, 8) к длине 1.
- 11.4 Центрируйте строки (2, 4) и (8, 10) по столбцам.
- 11.5 При каком c векторы (2, c) и (3, -2) ортогональны? Что это означает для двух признаков?

13. Разбор задач

13.1. Раздел 1

1.1. Натуральные — те, которыми считают предметы, начиная с единицы: 1, 17, 100. Ноль и -3 в $\mathbb{N}$ не входят. Целые — все пять чисел: $\mathbb{Z}$ содержит натуральные, ноль и отрицательные.

1.2. Сначала скобки и степень: $8 : 2 = 4$, $4^2 = 16$. Затем умножение: $3 \cdot 16 = 48$. Затем сложение и вычитание слева направо: $2 + 48 - 4 = 46$.

1.3. Деление с остатком: $1847 = 64 \cdot 28 + 55$. Полных батчей 28, хвост 55. Доля хвоста $55/1847 \approx 0,0298$, около трёх процентов. В коде: $1847 // 64$ и $1847 \% 64$. Если хвост отбросить, эти три процента не попадут в обучение текущей эпохи.

1.4. $180 = 2^2 \cdot 3^2 \cdot 5$, $12 = 2^2 \cdot 3$. Все простые множители делителя есть в 180, показатели не больше, значит $12 \mid 180$, частное 15.

1.5. $144 = 1 \cdot 96 + 48$, $96 = 2 \cdot 48 + 0$. Последний ненулевой остаток 48 есть НОД. НОК = $96 \cdot 144 / 48 = 288$.

1.6. Чётные: 0, 2, 4, ..., 14. Это восемь чисел: от нуля до четырнадцати через два, всего $(14 - 0)/2 + 1 = 8$.

1.7. $8! = 8 \cdot 7 \cdot 6!$, поэтому отношение равно 56. Полный $8! = 40320$ считать не нужно.

1.8. $19 = 3 \cdot 6 + 1$, остаток 1, индекс 19 в фолде 1. В фолде 1 лежат 1, 7, 13, 19 — четыре индекса из двадцати четырёх. Так `idx % 6` режет выборку на шесть почти равных частей.

1.9. $72000/1000 = 72$ с. $54 \cdot 5/18 = 15$ м/с.

1.10. $-15 + 8 = -7$, затем $-7 + 3 = -4$. $(-2)^3 = -8$, $-2^3 = -8$. Здесь показатели нечётные, поэтому оба ответа отрицательные, но по разным причинам: слева минус в основании три раза, справа степень тройки и минус снаружи.

1.11. До десятых: смотрят на $6 \geq 5$, получается 4,7. До сотых: смотрят на $0 < 5$, получается 4,65.

13.2. Раздел 2

2.1. $\text{НОД}(36, 54) = 18$, поэтому $\frac{36}{54} = \frac{2}{3}$. Далее $\frac{3}{8} = 0,375 = 37,5\% > 36\%$.

2.2. Пустых $0,08 \cdot 4000 = 320$. Заполненных 3680. Доля заполненных $3680/4000 = 23/25 = 0,92$.

2.3. Если $x = 0,(7)$, то $10x = 7,(7)$, вычитание даёт $9x = 7$, $x = 7/9$. Если $x = 0,2(3)$, то $10x = 2,(3)$, $100x = 23,(3)$, разность $90x = 21$, $x = 21/90 = 7/30$. Чистый период и период не сразу после запятой — тот же приём, что в теории для $0,1(6)$, другие цифры.

2.4. $\frac{15 \cdot 6 + 5 \cdot 2}{20} = \frac{100}{20} = 5$. Полусумма средних 4 была бы ошибкой: она забывает размеры групп.

2.5. $\text{Assurasy} = 41/50 = 0,82$. Знаменатель обязателен: одно и то же число верных ответов на разных объёмах даёт разные доли.

2.6. Знаменатель $10 = 2 \cdot 5$ в двоичной записи даёт период, поэтому 0,1 хранится приближённо. Тройка приближений не совпадает с приближением 0,3 бит в бит. Корректно: `numpy.isclose` с допуском либо `Rational(1,10)*3==Rational(3,10)`. Пример $0,1 + 0,2$ уже разобран в теории раздела 2 — здесь другой оператор на той же дроби.

2.7. $23 = 6 \cdot 3 + 5$, поэтому $\frac{23}{6} = 3\frac{5}{6}$. $4\frac{2}{5} = \frac{4 \cdot 5 + 2}{5} = \frac{22}{5}$.

$$2.8. \frac{2}{5} = 0,4 = 40\% > 38\%. \text{ Знаменатели } 15 = 3 \cdot 5 \text{ и } 21 = 3 \cdot 7, \text{ НОК} = 105. \frac{28}{105} + \frac{25}{105} = \frac{53}{105}.$$

13.3. Раздел 3

$$3.1. \frac{(x^2)^{-5}}{x^{-3}} = \frac{x^{-10}}{x^{-3}} = x^{-7} \cdot \frac{b^9}{b^4} = b^5.$$

$$3.2. \log_2 32 + \log_2 2 = \log_2 64 = 6, \text{ потому что } 2^6 = 64. \log_5 50 - \log_5 2 = \log_5 25 = 2, \text{ потому что } 5^2 = 25.$$

$$3.3. 3,4 \cdot 10^{-3} \text{ и } 7,2 \cdot 10^4.$$

$$3.4. \text{ Нужно } 500 \cdot 1,2^n > 2000, \text{ то есть } 1,2^n > 4, n > \ln 4 / \ln 1,2 \approx 7,60. \text{ Целое } n = 8. \text{ Проверка: } 1,2^7 \approx 3,58, 1,2^8 \approx 4,30.$$

$$3.5. \log_{10}(1, 10, 100, 1000) = (0; 1; 2; 3). \text{ Сдвиг } +1 \text{ делает выражение определённым в нуле: } \log(1 + 0) = 0. \text{ Большие счётчики почти не сдвигаются, нулевые не ломают столбец.}$$

13.4. Раздел 4

$$4.1. 7\% = 7/100 = 0,07.$$

$$4.2. \text{ Платят } 85\% = 17/20 \text{ цены, исходная цена } 680/0,85 = 800.$$

$$4.3. \text{ Абсолютный рост } 0,09, \text{ девять процентных пунктов. Относительный } 0,09/0,72 = 0,125 = 12,5\%. \text{ В отчёте пишут обе величины.}$$

$$4.4. \text{ Десять частей, одна часть } 360. \text{ Куски } 1800, 1080, 720. \text{ Это типичный split } 50/30/20.$$

$$4.5. \text{ Множитель } 1,1 \cdot 0,9 = 0,99, \text{ осталось } 99\% \text{ исходной величины. Складывать показатели нельзя: } +10 \text{ и } -10 \text{ в сумме ноль, но произведение множителей не единица.}$$

$$4.6. \text{ Простой: } 40000 \cdot (1 + 0,05 \cdot 2) = 44000. \text{ Сложный: } 40000 \cdot 1,05^2 = 44100. \text{ Разница } 100 \text{ есть процент на уже начисленные проценты.}$$

$$4.7. \text{ Положительных } 0,05 \cdot 400 + 0,20 \cdot 600 = 20 + 120 = 140. \text{ Строк } 1000. \text{ Доля } 140/1000 = 0,14 = 14\%. \text{ Полусумма долей } 12,5\% \text{ была бы верна только при равных размерах групп.}$$

$$4.8. \text{ Положительных во всей таблице } 0,12 \cdot 2000 = 240. \text{ Тест } 0,20 \cdot 2000 = 400 \text{ строк. Стратификация сохраняет долю } 12\%, \text{ значит в тесте } 0,12 \cdot 400 = 48 \text{ положительных. Вес класса } 1/0,12 = 25/3 \approx 8,33.$$

$$4.9. \text{ Вещества } 0,15 \cdot 12 = 1,8 \text{ кг, оно не уходит. Новая масса смеси } 1,8/0,20 = 9 \text{ кг.}$$

13.5. Раздел 5

$$5.1. 3x + 6 - 4 = x + 8, 3x + 2 = x + 8, 2x = 6, x = 3. \text{ Проверка: левая часть } 3(3 + 2) - 4 = 11, \text{ правая } 3 + 8 = 11.$$

$$5.2. D = 25 + 56 = 81, x = \frac{5 \pm 9}{2}, \text{ корни } 7 \text{ и } -2. \text{ Проверка по Виете: сумма } 5, \text{ произведение } -14.$$

$$5.3. 2x + 2 < x + 7, x < 5, \text{ ответ } (-\infty; 5). \text{ На таблице это фильтр строго меньше пяти.}$$

$$5.4. x(x - 6) \leq 0. \text{ Корни } 0 \text{ и } 6, \text{ ветви вверх, между корнями неположительно. Ответ } [0; 6].$$

$$5.5. \text{ Сложение: } 3x = 9, x = 3, \text{ тогда } y = 1. \text{ Проверка: } 2 \cdot 3 + 1 = 7, 3 - 1 = 2.$$

$$5.6. \text{ Неравенство } x \geq 1000. \text{ Подходят } 1800 \text{ и } 1100. \text{ В NumPy это булева маска } x \geq 1000.$$

$$5.7. \text{ Знаменатель не ноль: } x \neq 0. \text{ Числитель } x - 3 = 0 \text{ даёт } x = 3. \text{ Корень } 3 \text{ ограничению не противоречит, ответ } x = 3.$$

5.8. Пересечение луча $[-1; +\infty)$ и открытого луча $(-\infty; 3)$ есть полуинтервал $[-1; 3)$. На столбце это маска $(x \geq -1)$ and $(x < 3)$.

5.9. Корни -2 (кратно 2) и 5 (кратно 1). Чётная кратность знак не меняет, нечётная меняет. Знаки: минус на $(-\infty; -2)$, минус на $(-2; 5)$, плюс на $(5; +\infty)$. Неравенство нестрогое, ноль входит. Ответ $(-\infty; 5]$. Точка -2 уже внутри этого луча, отдельно её писать не нужно.

5.10. Нули: -1 (числитель, выколот, потому что знак строгий) и 3 (знаменатель, всегда выколот). Знаки: плюс на $(-\infty; -1)$, минус на $(-1; 3)$, плюс на $(3; +\infty)$. Нужен плюс: $x \in (-\infty; -1) \cup (3; +\infty)$. Точку 3 нельзя закрасить: на ней знаменатель ноль, выражения нет. Умножать неравенство на $x - 3$ нельзя по той же причине.

5.11. Первое: $x \in [0; +\infty)$. Второе: $x < 2$. Пересечение $[0; 2)$. В таблице это фильтр «признак неотрицателен и строго меньше двух».

5.12. $x^2 - 9 = (x - 3)(x + 3) = 0$, корни ± 3 . $x^2 + 9 = 0$ в действительных числах корней нет: квадрат не бывает -9 .

13.6. Раздел 6

6.1. Значения $3; 2,5; 2; 1,5; 1$. Наклон $-1/4$: каждый шаг на две единицы вправо опускает график на половину.

6.2. Оба расстояния равны 13. Норма не зависит от знака координат: $(-5)^2 = 5^2$.

6.3. $\frac{50 - 20}{80 - 20} = \frac{1}{2}$. Середина отрезка перешла в середину единичного — свойство линейной функции.

6.4. $x^2 - 6x + 8 = (x - 2)(x - 4)$, нули 2 и 4. Вершина $x = 3$, значение -1 .

6.5. $x = 8$. Слева от восьми оценка отрицательна, справа положительна. Порог $s(x) \geq 0$ отбирает объекты с $x \geq 8$.

13.7. Раздел 7

7.1. $a_{10} = 4 + 9 \cdot 5 = 49$. $S_{10} = \frac{10}{2}(4 + 49) = 265$.

7.2. $b_6 = 3 \cdot 2^5 = 3 \cdot 32 = 96$.

7.3. Месячная ставка $0,12/12 = 0,01$. $S_6 = 20000 \cdot 1,01^6 = 20000 \cdot 1,06152 \dots \approx 21230,4$.

7.4. $a_n = 40 + (n - 1) \cdot 2 = 2n + 38 \geq 50$, откуда $n \geq 6$. Шестой член равен 50.

7.5. $s_1 = \frac{1}{3} \cdot 12 = 4$, $s_2 = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 4 = \frac{8}{3}$, $s_3 = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot \frac{8}{3} = \frac{16}{9}$. Без новых сигналов оценка тает со знаменателем $1 - \alpha = 2/3$.

13.8. Раздел 8

8.1. $12 + 9 - 16 = 5$. Если A и B — строки с пропуском в первом и втором столбце, то пять строк имеют пропуск сразу в обоих, а объединение 16 есть число строк хотя бы с одной из двух дырок.

8.2. $C_5^2 = 10$.

8.3. $A_5^2 = 5 \cdot 4 = 20$ — упорядоченные пары. $C_5^2 = 10$ — неупорядоченные. Каждую неупорядоченную пару посчитали дважды, когда считали размещения.

8.4. Пересечение $\{8\}$. Утечка есть: объект 8 видели и при обучении, и при проверке.

8.5. $C_{12}^2 = 66$. Это число неупорядоченных пар среди двенадцати объектов: столько pairwise-сравнений.

13.9. Раздел 9

9.1. Сумма 30, среднее 6. Упорядоченный ряд уже дан, медиана средний член 4. Размах $13 - 2 = 11$. Отклонения от 6: $-4, -2, -2, 1, 7$. Квадраты: 16, 4, 4, 1, 49, сумма 74. $s^2 = 74/4 = 18,5$.

9.2. $\frac{5 \cdot 8 + 15 \cdot 4}{20} = 5$. Не 6: две группы разного размера.

9.3. Было среднее и медиана 11,5. Стало среднее $146/5 = 29,2$, медиана 12. Типичный чек — медиана: один выброс её почти не сдвинул.

9.4. Среднее 4, $s^2 = ((2 - 4)^2 + (4 - 4)^2 + (6 - 4)^2)/2 = 4$, $s = 2$. Тогда $z = (-1, 0, 1)$, сумма нуль. Это всегда так после центрирования.

9.5. Совпадают на симметричном ряде, например 1, 2, 3, 4, 5. Различаются при выбросе, например 1, 2, 3, 4, 100: среднее 22, медиана 3.

13.10. Раздел 10

10.1. Первая вероятность $3/8$. После извлечения синего в урне осталось семь камней, из них два синих, вторая вероятность $2/7$. Оба синих подряд без возвращения: $\frac{3}{8} \cdot \frac{2}{7} = \frac{3}{28}$.

10.2. Независимость даёт пересечение $0,4 \cdot 0,5 = 0,2$. Объединение $0,4 + 0,5 - 0,2 = 0,7$.

10.3. Полная вероятность теста:

$$P(T) = 0,95 \cdot 0,02 + 0,10 \cdot 0,98 = 0,019 + 0,098 = 0,117.$$

Байес:

$$P(D | T) = \frac{0,95 \cdot 0,02}{0,117} = \frac{0,019}{0,117} \approx 0,162.$$

Даже хороший тест на редкой болезни оставляет около 16% апостериорной вероятности: знаменатель раздувают ложные тревоги на 98% здоровых.

10.4. $C_8^3/2^8 = 56/256 = 7/32$.

10.5. Precision $30/40 = 3/4$: среди тех, на кого модель показала пальцем, три четверти были истинной. Recall $30/50 = 3/5$: среди всех истинных плюсов поймали три пятых. Это разные дроби с разным знаменателем.

13.11. Раздел 11

11.1. Сумма $(4, 5)$. $2\vec{a} - \vec{b} = (6, 2) - (1, 4) = (5, -2)$. Произведение $3 \cdot 1 + 1 \cdot 4 = 7$.

11.2. Произведение 1, длины 1 и $\sqrt{2}$, косинус $1/\sqrt{2}$, угол 45° .

11.3. Длина $\sqrt{36 + 64} = 10$, единичный вектор $(3/5, 4/5)$.

11.4. Средние столбцов $\frac{2+8}{2} = 5$ и $\frac{4+10}{2} = 7$. Центрированные строки $(2 - 5, 4 - 7) = (-3, -3)$ и $(8 - 5, 10 - 7) = (3, 3)$.

11.5. Произведение $6 - 2c = 0$, откуда $c = 3$. Ортогональность двух векторов признаков означает, что их направления не дают взаимной проекции: в линейной модели вклад одного не дублирует вклад другого вдоль этой оси.